ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ «САМАРСКИЙ НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
ИМЕНИ АКАДЕМИКА С.П. КОРОЛЕВА

Лекции по курсу «Нейронные сети и машинное обучение»

Для студентов направления 090401

Очное обучение 2026-2027 учебный год

Лектор: Солдатова Ольга Петровна, к.т.н., доцент

Модели машинного обучения

Лекция 3

Машинное обучение и признаки.

Признаки и разбиение пространства.

Дискриминантный анализ.

Линейный дискриминант Фишера.

Задача линейной регрессии.

Логистическая регрессия.

Метод опорных векторов.

Литература по курсу

1. Куприянов А.В. «Искусственный интеллект и машинное обучение» https://do.ssau.ru/moodle/course/view.php?id=1459
2. Осовский С. Нейронные сети для обработки информации / Пер. с пол. И.Д. Рудинского. – М.: Финансы и статистика, 2002. – 344 с.: ил.
3. Горбаченко, В. И. Интеллектуальные системы: нечеткие системы и сети : учебное пособие для вузов / В. И. Горбаченко, Б. С. Ахметов, О. Ю. Кузнецова. — 2-е изд., испр. и доп. — Москва : Издательство Юрайт, 2018. — 105 с. — (Университеты России). — ISBN 978-5-534-08359-0. — Текст : электронный // ЭБС Юрайт [сайт]. — URL: https://urait.ru/bcode/424887 – Режим доступа: https://urait.ru/bcode/424887
4. 4. Гафаров Ф.М. Искусственные нейронные сети и приложения: учеб. пособие / Ф.М. Гафаров, А.Ф. Галимянов. – Казань: Изд-во Казан. ун-та, 2018. – 121 с. – Текст : электронный. – Режим доступа: https://repository.kpfu.ru/?p_id=187099
5. Хайкин С. Нейронные сети: Полный курс: Пер. с англ. - 2-е изд. – М.: Вильямс, 2006. – 1104 с.: ил.
6. Борисов В.В., Круглов В.В., Федулов А.С. Нечёткие модели и сети. – М.: Горячая линия– Телеком, 2007. -284 с.: ил.
7. Рутковская Д., Пилиньский М., Рутковский Л. Нейронные сети, генетические алгоритмы и нечёткие системы: Пер. с польск. И.Д.Рудинского, - М.: Горячая линия – Телеком, 2007. – 452 с. ил.
8. Николенко С., Кадурин А., Архангельская Е. Глубокое обучение. — СПб.: Питер, 2018. — 480 с.: ил. — (Серия ≪Библиотека программиста≫).
9. Гудфеллоу Я., Бенджио И., Курвилль А. Глубокое обучение / пер. с анг. А. А. Слинкина. – 2-е изд., испр. – М.: ДМК Пресс, 2018. – 652 с.: цв. ил.

Машинное обучение и признаки

Существуют два множества:

- ✓ Множество *объектов – образов X*
- ✓ Множество *ответов Y*

Существует целевая функция $y^* : X \to Y$ значения которой известны только на конечном подмножестве объектов:

- ✓ Пары «объект-ответ» :
- ✓ $\{x_1, \ldots, x_n\} \subset X$ называются прецедентами.
- ✓ Совокупность пар (x_i, y_i)
- ✓ $X^N = (x_i, y_i)_{i=1}^N$ называется обучающей выборкой.

Требуется построить отображение (гипотезу)

$$a : X \to Y; \qquad a(x) = y \in Y$$

- ✓ Признак – это результат измерения некоторой отличительной характеристики объекта, качественной или количественной.
- ✓ Признаком называется отображение

$$f : X \to D_f$$

Основные проблемы построения признаков

- Как определять признаки : размышления, эксперименты, консультации и т.п.
- Как искать закономерности : перебором подмножеств признаков.
- Как объединять закономерности в алгоритм: любым классификатором.
- Как определять информативность?

Классификация – это ***метод построения информативных признаков***.

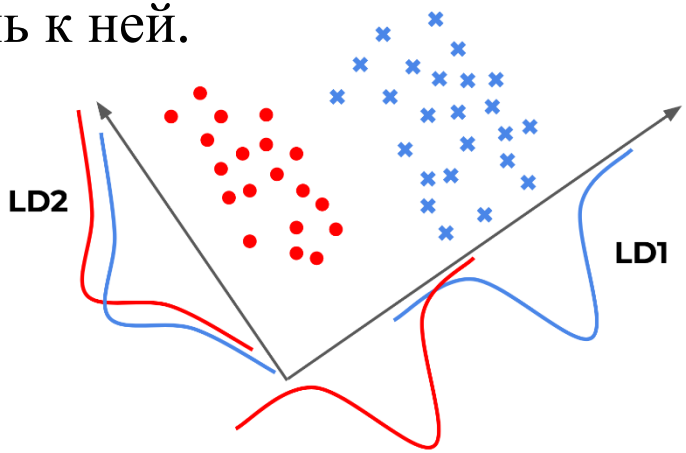
Признаки и разбиение пространства

- Задача классификации: определить вектор x в один из K классов Y .
- Ищем линейную дискриминантную функцию определяющую разделяющую поверхность между классами $y(x) = w^T x + w_0$.

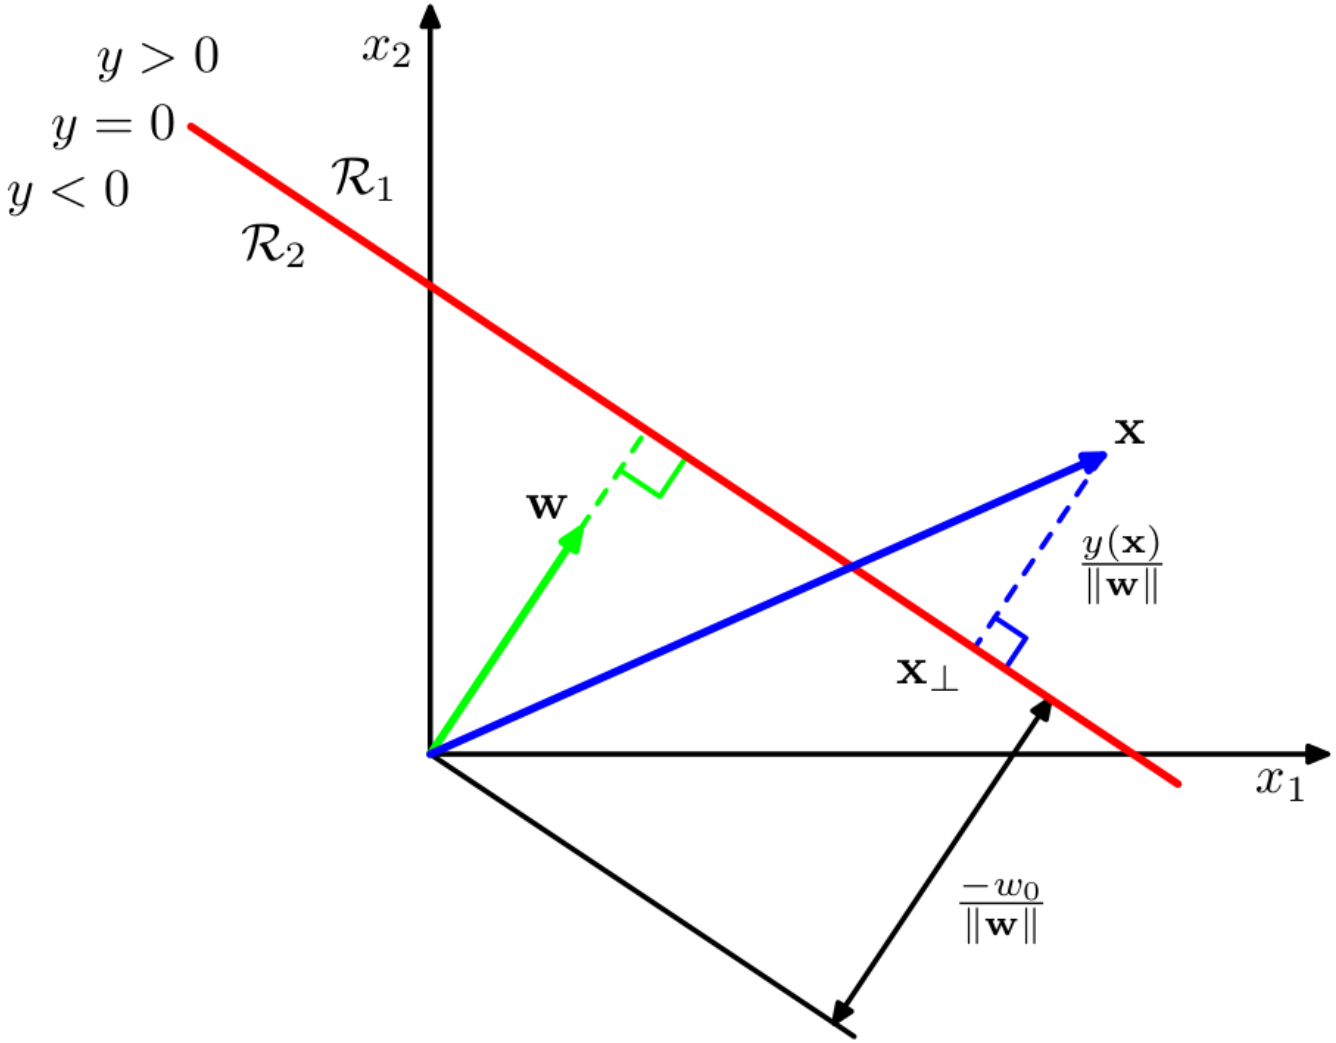
Это гиперплоскость, и w– нормаль к ней.

Расстояние от начала координат до гиперплоскости равно $-\frac{w_0}{\|w\|}$.

$y(x)$ связано с расстоянием до гиперплоскости: $d = \frac{y(x)}{\|w\|}$.



Разбиение пространства, как задача классификации

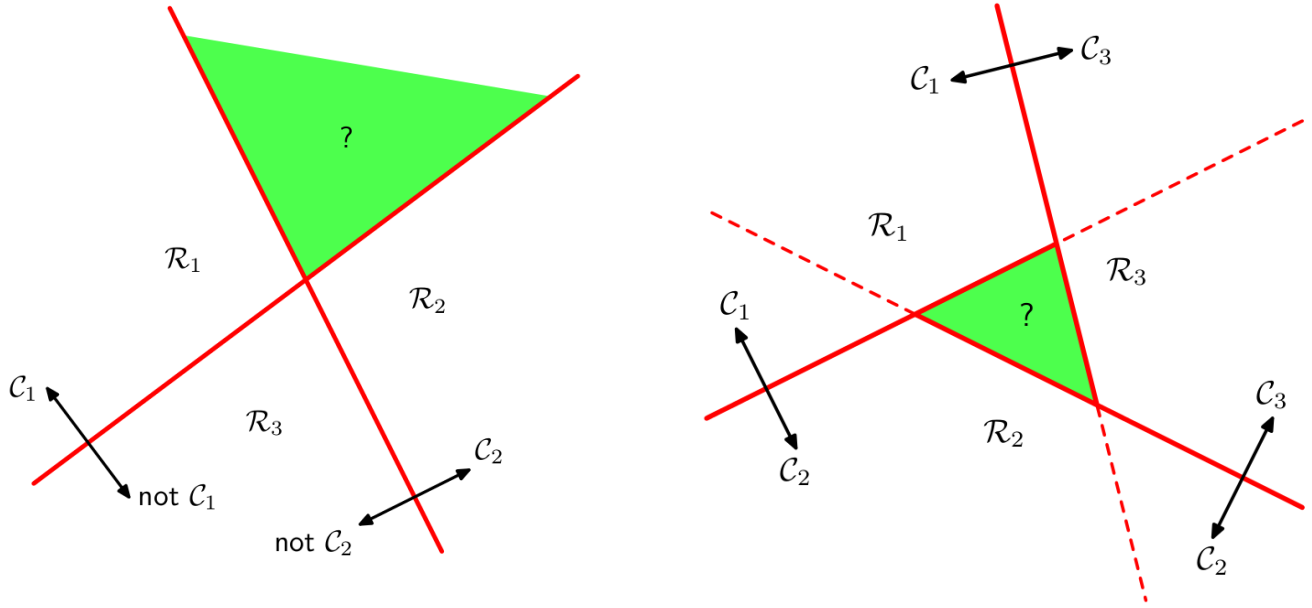


Разделение на несколько классов

- Можно рассмотреть поверхности вида «один против всех».
- Можно рассмотреть поверхности вида «каждый против каждого».
- Можно рассмотреть единый дискриминант из k линейных функций вида

$$y_k(x) = w_k{}^T x + w_{k0} \quad .$$

Классифицируем в Y_k если соответствующий y_k – максимален.



Дискриминантный анализ

Дискриминантный анализ – это общий термин, относящийся к нескольким тесно связанным статистическим процедурам решения задач различения (дискриминации) объектов наблюдения по набору признаков.

- Линейный ДА пытается выразить какую-либо зависимую переменную через линейную комбинацию других признаков или измерений.
- Как в дисперсионном и регрессионном анализе зависимая переменная — численная величина, является величиной номинальной (меткой класса).

Основной целью дискриминации является поиск линейной комбинации признаков (называемых дискриминантными признаками), которые позволили бы наилучшим образом разделить рассматриваемые группы.

Задачи дискриминантного анализа

- Определение дискриминирующих признаков (т.е. признаков, которые позволяют отнести наблюдение к той или иной группе);
- Построение дискриминирующей функции;
- Прогнозирование будущих событий, связанных с попаданием объекта в ту или иную группу на основе значений его признака (например, предсказание выживаемости пациента после операции).

Методы интерпретации межгрупповых различий (дискриминации) позволяют ответить на следующие вопросы:

- ✓ Возможно ли, используя данный набор переменных, отличить одну группу от другой?
- ✓ Насколько хорошо эти переменные позволяют провести дискриминацию?
- ✓ Какие из них наиболее информативны, а какие могут быть удалены из пространства признаков в связи с избыточностью?

Линейный дискриминант Фишера

Линейный дискриминант Фишера в первоначальном значении - метод, определяющий расстояние между распределениями двух разных классов объектов, является частным случаем гауссового байесовского классификатора. Он используется в задачах машинного обучения при статистическом (байесовском) подходе к решению задач классификации.

Предположим, что обучающая выборка удовлетворяет помимо базовых гипотез байесовского классификатора также следующим гипотезам:

- Классы распределены по нормальному закону.
- Матрицы ковариаций классов равны.

Тогда статистический подход приводит к линейному дискриминанту, и именно этот алгоритм классификации в настоящее время часто понимается под термином линейный дискриминант Фишера.

При равенстве всех ковариационных матриц разных классов, достаточно оценить векторы математических ожиданий и общую ковариационную матрицу уже по всем объектам обучающей выборки.

То есть, математические ожидания разные для каждого класса, а ковариационная матрица общая.

Линейный дискриминант Фишера

Подход, который предложил Фишер, заключается в следующем:

- ✓ В линейном случае следует спроецировать точки в размерность 1 (на нормаль разделяющей гиперплоскости) так, чтобы в этой размерности 1 они «хорошо» разделялись.
- ✓ То есть классификация – это ***метод радикального сокращения размерности***.

Рассмотрим классификацию с этих позиций и попробуем добиться оптимальности в каком-то смысле.

Линейный дискриминант Фишера

Рассмотрим два класса C_1 и C_2 с N_1 и N_2 точками.

- **Идея 1** – найдём серединный перпендикуляр между центрами кластеров, так как мерой разделения спроецированных точек служит разность средних значений выборки:

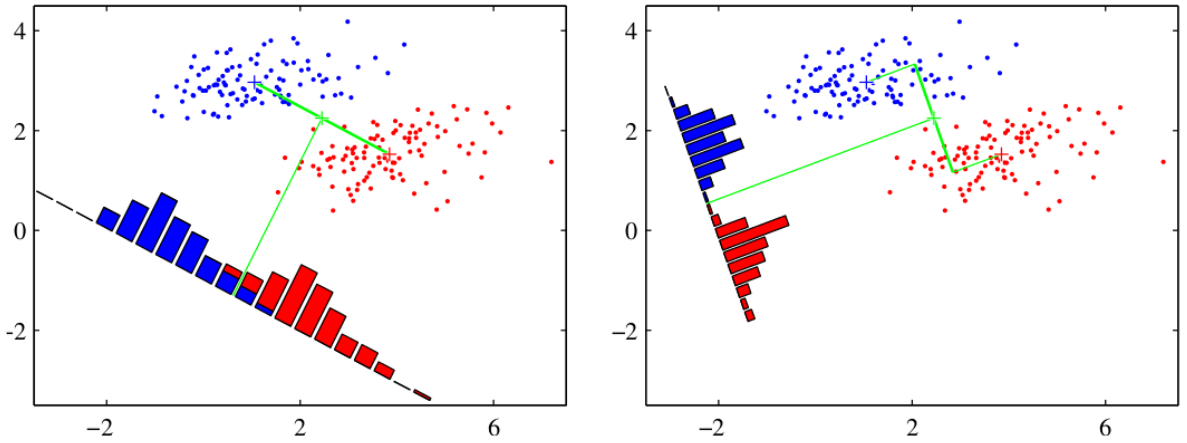
$$m_1 = \frac{1}{N_1}\sum_{C_1} x \qquad , \qquad m_2 = \frac{1}{N_2}\sum_{C_2} x$$

- Будем максимизировать эту разность: $w^T(m_2 - m_1) \longrightarrow \max, \|w\| = 1$
- Вместо получения дисперсий выборок определим разброс для спроецированных выборок, который будет являться оценкой выборочных дисперсий для проекции.

Для $y_n = w^T x_n$ выборочные дисперсии:

$$s_1 = \sum_{C_1}(y_n - m_1)^2 \qquad s_2 = \sum_{C_2}(y_n - m_2)^2$$

Линейный дискриминант Фишера

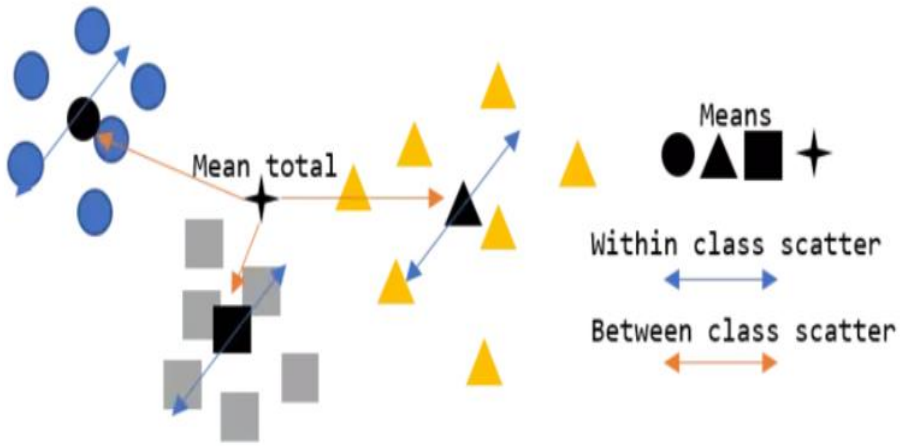


- Чем отличается левый случай от правого?
- Слева больше дисперсия каждого кластера.
- **Идея 2:** минимизировать перекрытие классов, оптимизируя и проекцию расстояния, и дисперсию.

Линейный дискриминант Фишера

- Критерий Фишера

$$J(w) = \frac{(m_2 - m_1)^2}{s_1^2 + s_2^2} = \frac{w^T S_B w}{w^T S_W w}$$



$$S_B = (m_2 - m_1)(m_2 - m_1)^T$$

– ковариация между классами (between-class)

$$S_W = \sum_{C_1} (x_n - m_1)(x_n - m_1)^T + \sum_{C_2} (x_n - m_2)(x_n - m_2)^T$$

– ковариация внутри классов (within-class)

Линейный дискриминант Фишера

Ищется максимум критерия Фишера.

Критерий Фишера максимален, когда $\left(w^T S_B w\right) S_W w = \left(w^T S_W w\right) S_B w$

Так как $S_B w$ будет в направлении $m_2 - m_1$, а длина w не имеет значения, получим: $w \propto S_w^{-1}(m_2 - m_1)$

Для случая нескольких классов обобщим критерий Фишера:

$$J(w) = \left\| S_W^{-1} S_B \right\|$$

$S_W = \sum_{k=1}^{K} \sum_{C_k} (x_n - m_1)(x_n - m_1)^T$ – внутренняя дисперсия

$S_B = S_T - S_W$ – внешняя (межклассовая) дисперсия

$S_T = \sum_{n} (x_n - m)(m_n - m)^T$ – полная дисперсия

Особенности дискриминантного анализа

Для выбранных переменных рассчитывается новая переменная Z (дискриминантная функция) – **линейная комбинация** исходных переменных, которая наилучшим образом разделит группы.

✓ Если группы две: получается одно уравнение .

✓ Когда групп много, получают **несколько дискриминантных функций**, «перпендикулярных» друг другу. Чем больше коэффициент при переменной, тем лучше она разделяет группы, но не говорит, какие именно

$$Y = w_0 + w_1 x_1 + w_2 x_2 + w_3 x_3 + ..:$$

Требования к обучающим выборкам:

1. Внутри классов должно быть многомерное *нормальное распределение* (оценка – на основе построения гистограмм частот);

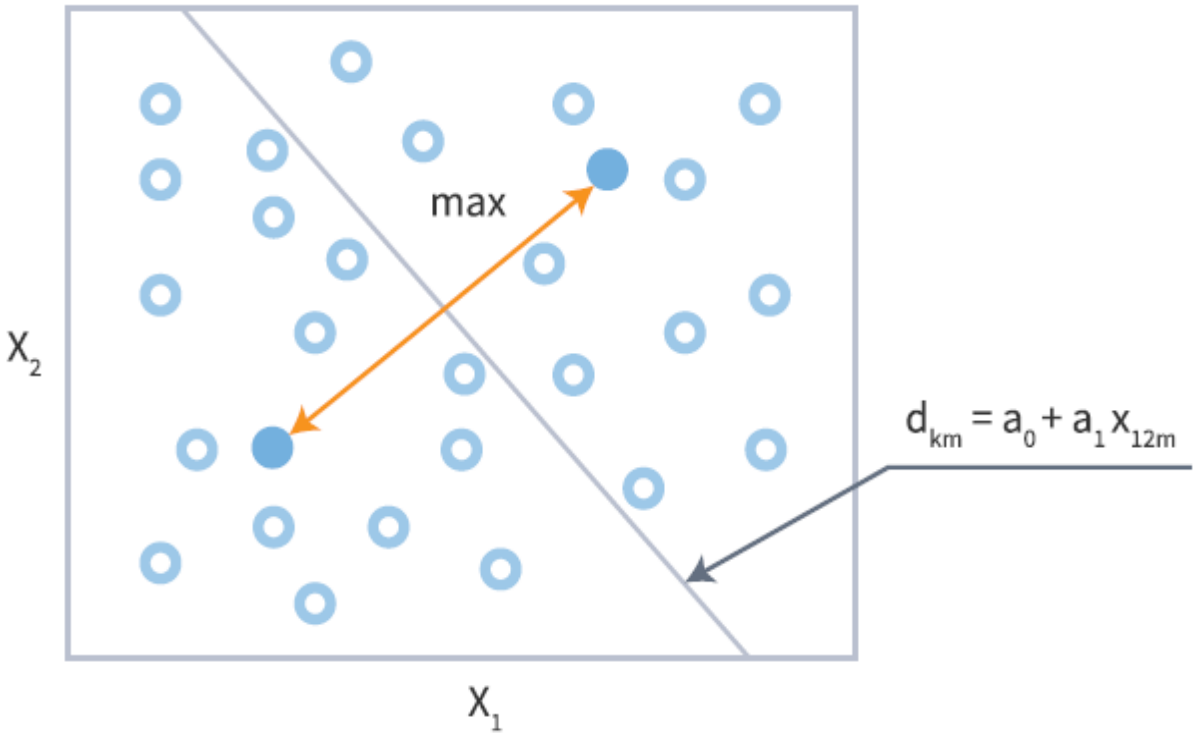
2. Гомогенность внутриклассовых *дисперсий* (не очень критичное требование);

3. Не должно быть корреляции *средних* значений и *дисперсий* в классах;

4. Не должно быть чрезмерно коррелирующих друг с другом переменных

Дискриминантная функция рассчитывается **только** для тех измерений, для которых *известно, к какому классу они принадлежат* (т.е., только для тех образов, для которых класс известен).

Особенности дискриминантного анализа



Особенности дискриминантного анализа

Требования к обучающим выборкам:

1. Внутри классов должно быть многомерное *нормальное распределение* (оценка – на основе построения гистограмм частот);

2. Гомогенность внутриклассовых *дисперсий* (не очень критичное требование к дисперсиям, когда для разных классов дисперсии примерно равны);

3. Не должно быть корреляции *средних* значений и *дисперсий* в классах;

4. Не должно быть чрезмерно коррелирующих друг с другом переменных

Дискриминантная функция рассчитывается **только** для тех измерений, для которых *известно, к какому классу они принадлежат* (т.е., только для тех образов, для которых класс известен).

Пример: дискриминантный анализ лемуров

- Изучение лемуров на Мадагаскаре.
- Есть 3 вида лемуров, поймали зверьков разных видов, взвесили, измерили голову и зубы.
- Вопрос: по какой из переменных лучше всего отличимь виды?







Пример: дискриминантный анализ лемуров

- Мы изучаем лемуров на Мадагаскаре.
- У нас 3 вида лемуров, мы поймали зверьков разных видов, взвесили, померили голову и зубы.
- Вопрос: по какой из переменных мы лучше всего отличим виды?



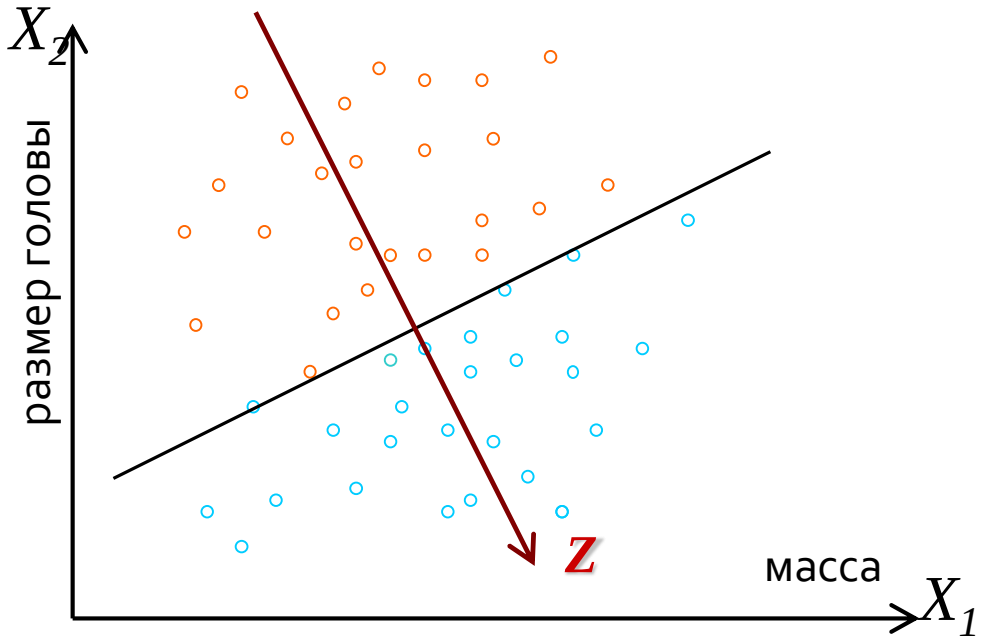




Пример дискриминантный анализ лемуров

Оказалось, что, несмотря на то, что средние значения для каждой переменной у разных видов отличаются, их распределения сильно перекрываются и для массы, и для головы, и для зубов!

Переменная *Z* (дискриминантная функция) строится таким образом, чтобы как можно больше зверьков одного из видов получили высокие значения *Z*, и как можно больше зверьков другого вида – низкие значения Z



Задача линейной регрессии

- **Нужно найти функцию, которая отображает зависимость одних переменных или данных от других.**
- Зависимые данные называются **зависимыми переменными, выходами** или **ответами.**
- Независимые данные называются **независимыми переменными, входами или предсказателями.**
- Обычно в регрессии присутствует одна непрерывная и неограниченная зависимая переменная.
- Входные переменные могут быть неограниченными, дискретными или категорическими данными.

Задача линейной регрессии

Возможных функций отображений может быть много, но можно упростить задачу и искать решение только в самом простом семействе функций — линейным функциям вида

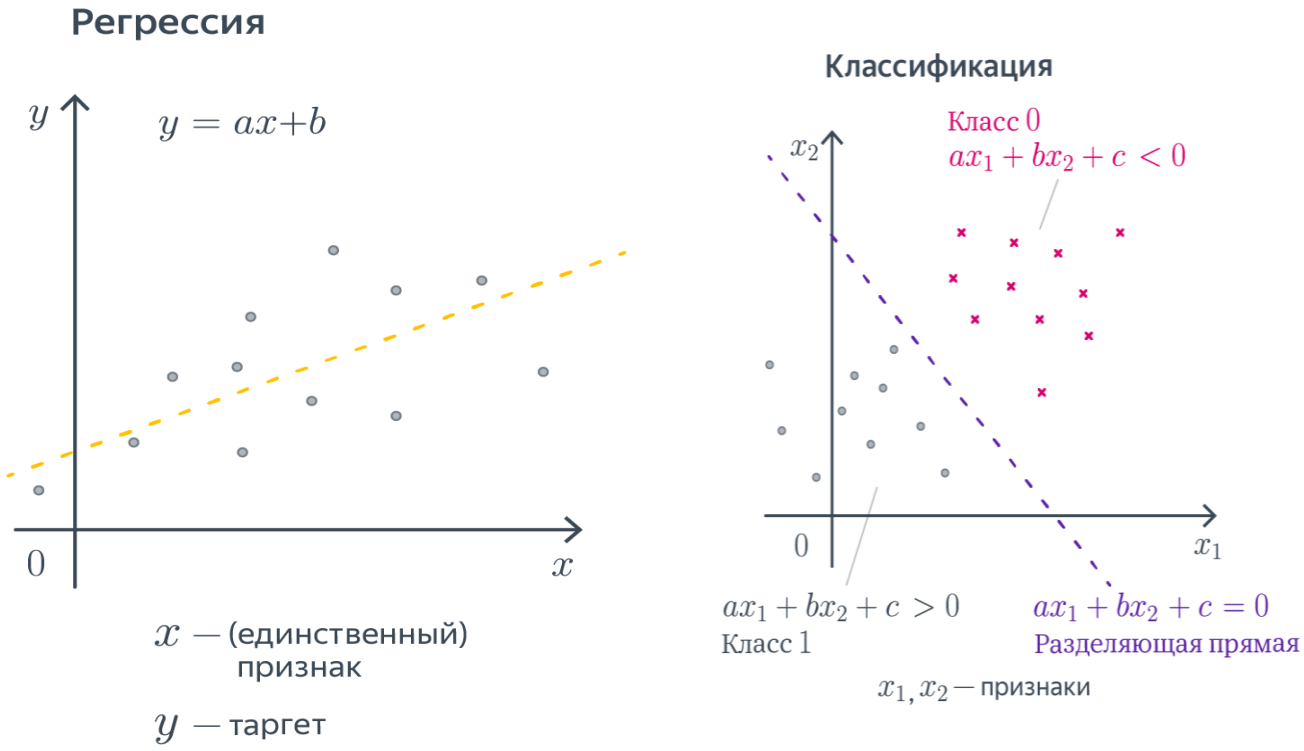
$$y = w_1 x_1 + w_2 x_2 + \ldots + w_D x_D + w_0 \quad ,$$

где y – независимая переменная (таргет), $(x_1, x_2, \ldots, x_D)$ -вектор, соответствующий зависимым входным переменными (вектор признаков), а $w_1, w_2, \ldots, w_D, w_0$ – параметры модели. Вектор $w = (w_1, w_2, \ldots, w_D)$ часто называют вектором весов, так как на ответ модели можно смотреть как на взвешенную сумму признаков объекта, а число w_0 – является свободным коэффициентом, или сдвигом. Более компактно линейную модель можно записать в виде:

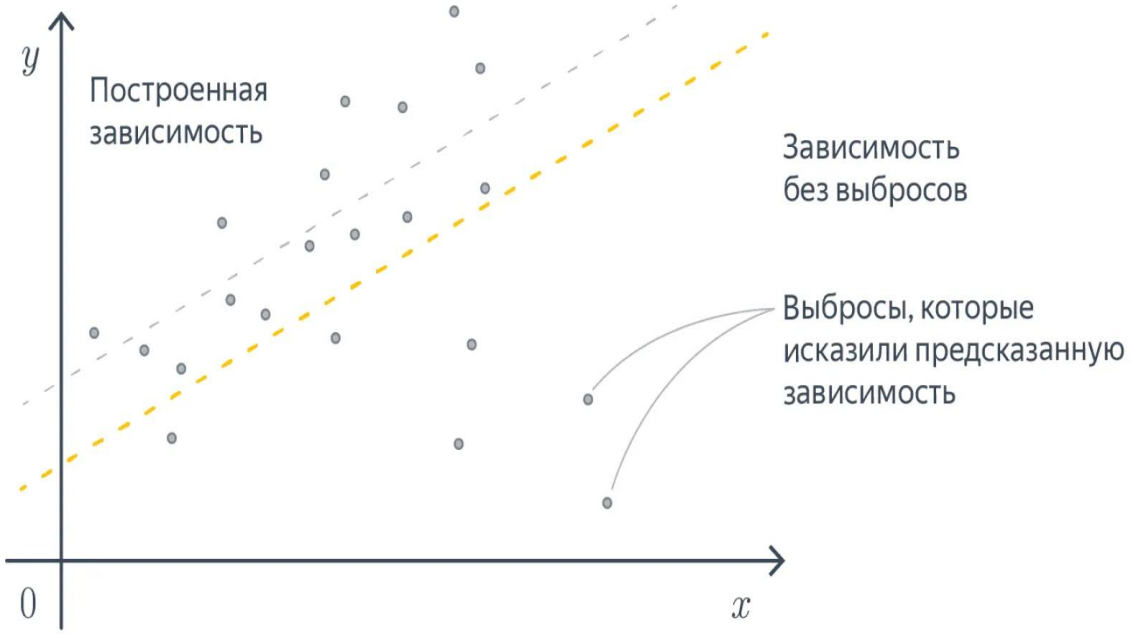
$$y = \langle x, w \rangle + w_0 \quad .$$

Если D=1, то у объектов есть ровно один численный признак, по которому они отличаются. Теперь линейная модель будет выглядеть совсем просто: $y = w_1 x_1 + w_0$. Для бинарной классификации объектов следует искать так называемое разделяющее правило: там, где значение функции положительно, определяется один класс объектов, где отрицательно – другой.

Модели алгоритмов для решения задач регрессии и классификации



Задача линейной регрессии



Задача линейной регрессии

Требуется, чтобы на датасете (то есть на парах (x_i, y_i) из обучающей выборки) функция f_w как можно лучше приближала искомую зависимость.

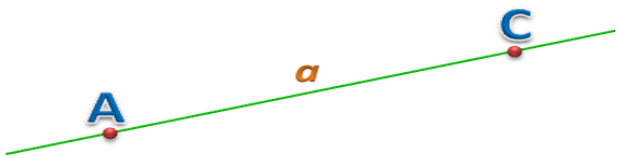
Для того, чтобы чётко сформулировать задачу, следует на математическом языке выразить желание «приблизить $f_w(x)$ к y», то есть необходимо научиться измерять качество модели и минимизировать её ошибку, изменяя обучаемые параметры. В данном примере обучаемые параметры — это веса w. Функция, оценивающая то, как часто модель ошибается, традиционно называется функцией ошибки, функционалом ошибки или *loss function*.

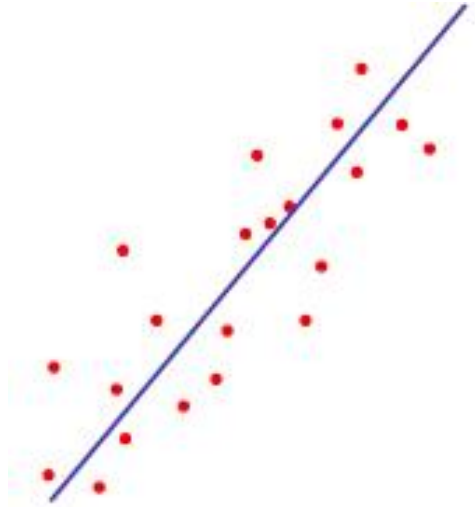
Для решения задачи требуется минимизировать функционал ошибки.

Для линейной регрессии для этого используется метод наименьших квадратов (МНК).

Задача линейной регрессии

Через две точки на плоскости можно провести только одну прямую.





Что делать, если точек на плоскости – три и более?

Метод наименьших квадратов (МНК) состоит в том, чтобы найти такие коэффициенты регрессии, при которых достигается минимум следующего функционала ошибки на заданной обучающей выборки:

$$y_i' = y_k'(x_i) = w_k^T x_i + w_k^0$$

$$\sum_i (y_i - y_i')^2 = \sum_i (y_i - w_k^T x_i + w_k^0)^2 \xrightarrow{k} \min$$

Логистическая регрессия

Логистическая регрессия — это статистический метод и алгоритм машинного обучения, используемый для прогнозирования вероятности возникновения бинарного события (ответ 0 или 1, «да» или «нет») на основе одного или нескольких признаков. Несмотря на название, это метод классификации, который моделирует данные с помощью S-образной сигмоидной кривой, возвращая значения от 0 до 1.

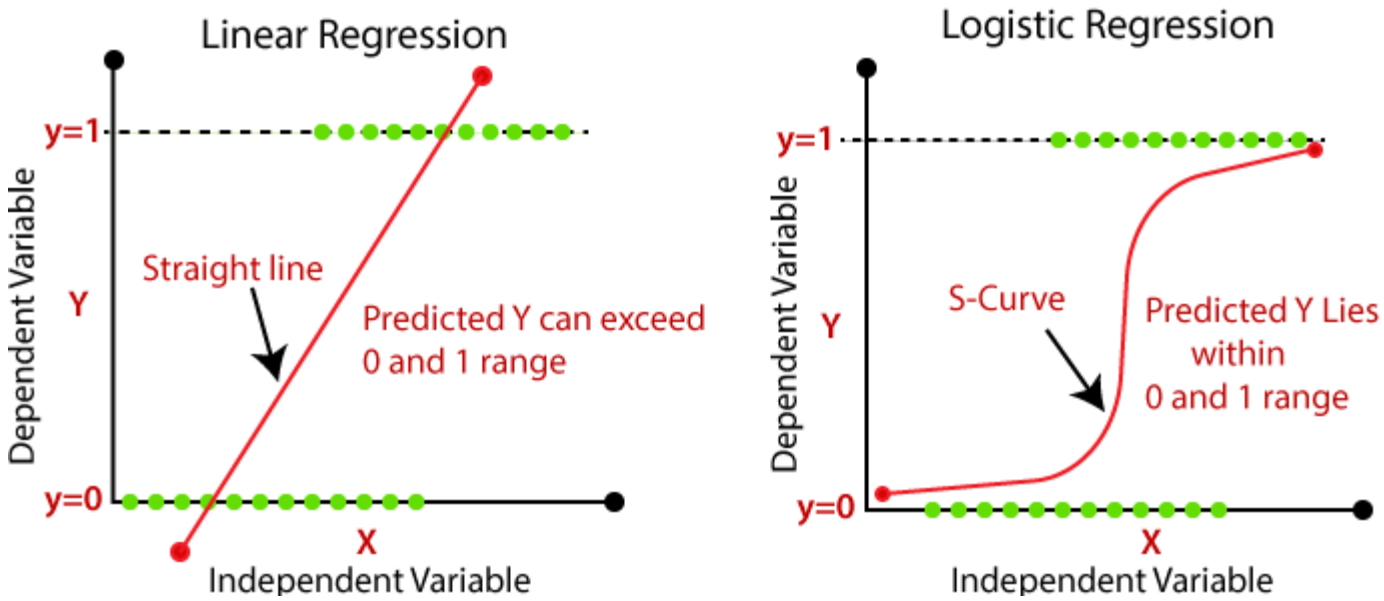
Логистическая регрессия использует сигмоидную функцию, чтобы преобразовать линейную комбинацию признаков

$$y = w_1 x_1 + w_2 x_2 + \ldots + w_D x_D + w_0$$

в вероятность $f(y) = \frac{1}{1+e^{-y}}$,

что позволяет оценивать апостериорные вероятности принадлежности классам.

Линейная и логистическая регрессия



Логистическая регрессия

Функция в правой части называется сигмоидой и обозначается

$$\sigma(y) = \frac{1}{1 - e^{\langle y \rangle}}$$

Таким образом, $p = \sigma(\langle w, x_i \rangle)$

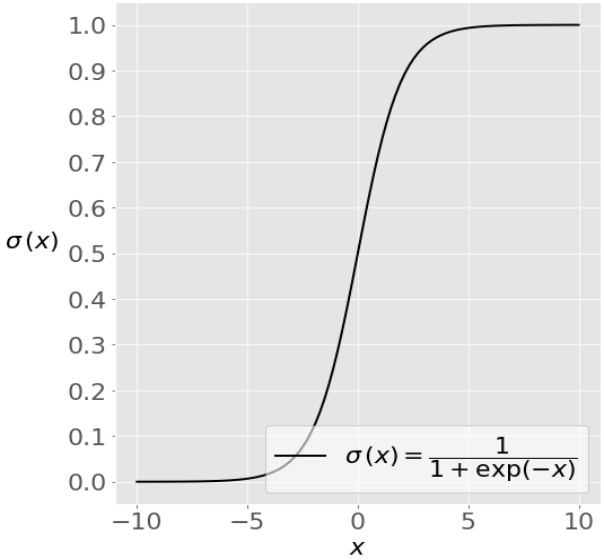
Логистическая регрессия вычисляет вероятность того, что данное исходное значение принадлежит к определенному классу. Она используется для задач классификации: оценивает апостериорные вероятности принадлежности данного объекта к тому или иному классу.

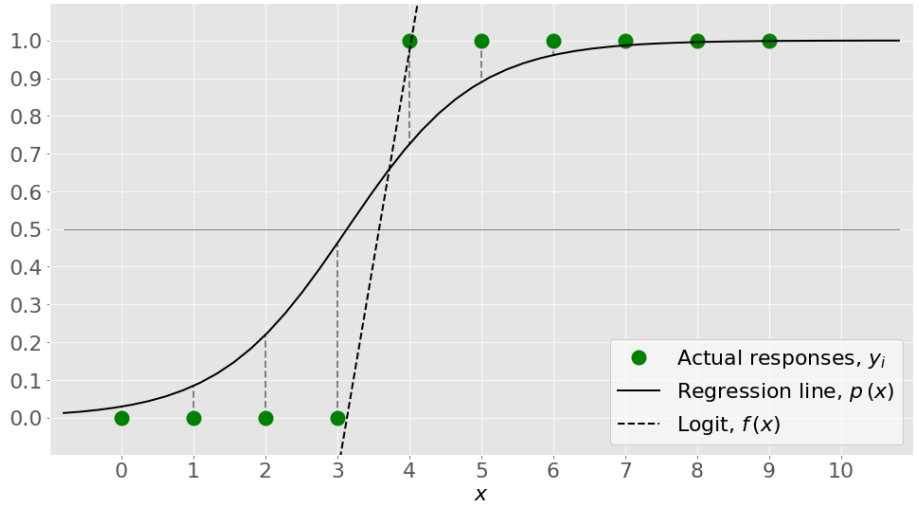
Для оценки модели логистическая регрессия применяет метод **максимального правдоподобия.** Он основан на предположении о том, что вся информация о статистической выборке содержится в функции правдоподобия. Цель метода – оценить параметры распределения вероятностей. Способ – максимизировать функцию правдоподобия.

Эта функция как раз определяет вероятность значений параметров регрессионной модели для заданного значения независимой переменной x=X: $P(\theta)=P(x=X|\theta)$, где θ — значение параметра модели, $P(\theta)$ — вероятность появления значения θ, X — значение независимой переменной x, для которого определяется условная вероятность θ.

Задача заключается в поиске таких значений параметров $\Theta = (\theta 1, \theta 2,...,\theta n)$, которые максимизируют функцию правдоподобия $L(x|\Theta)$. Для этого определяются оценки максимального правдоподобия, для которых значения параметров являются наиболее «правдоподобными» по отношению к наблюдаемым данным.

Логистическая регрессия





$$f(y) = \frac{1}{1+e^{-y}}$$ – логистическая функция

$$y = \sum_n w_n x_n$$ – линейная регрессия

Логистическая регрессия

Это линейный классификатор, оценивающий апостериорные вероятности классов $P(y/x)$, необходимые в задачах оценивания рисков.

Регуляризация улучшает обобщающую способность логистической регрессии :

- *L2 – регуляризация сокращает веса линейно зависимых признаков;*
- *L1 – регуляризация для отбора признаков.*

Для оценки коэффициентов регрессии обычно применяется метод оценки максимального правдоподобия

Линейная и логистическая регрессия

Критерий сравнения	Линейная регрессия	Логистическая регрессия
Ввод – вывод	Ввод – независимая переменная (или несколько), вывод – прогноз зависимой переменной (задача регрессии)	Ввод – независимая переменная (или несколько), вывод – вероятность принадлежности к группе
Линия наилучшего соответствия	Прямая	Кривая
Способ минимизации ошибки	Метод наименьших квадратов	Метод максимального правдоподобия.
Результат на выходе	**Вещественное число** (прогноз изменений)	**Число в интервале от 0 до 1.** Можно осуществить бинарную классификацию: если число ниже порогового значения — то объект относится к 0 («нет»), а если выше — то к 1 («да»)
Цель	**Прогнозирование** линейных трендов	**Классификация** (при добавлении соответствующего правила), но классификатором при этом не является

Метод опорных векторов (SVM): оптимальная гиперплоскость

Линейный дискриминант Фишера и МНК ищут разделяющую гиперплоскость, но не оптимально.

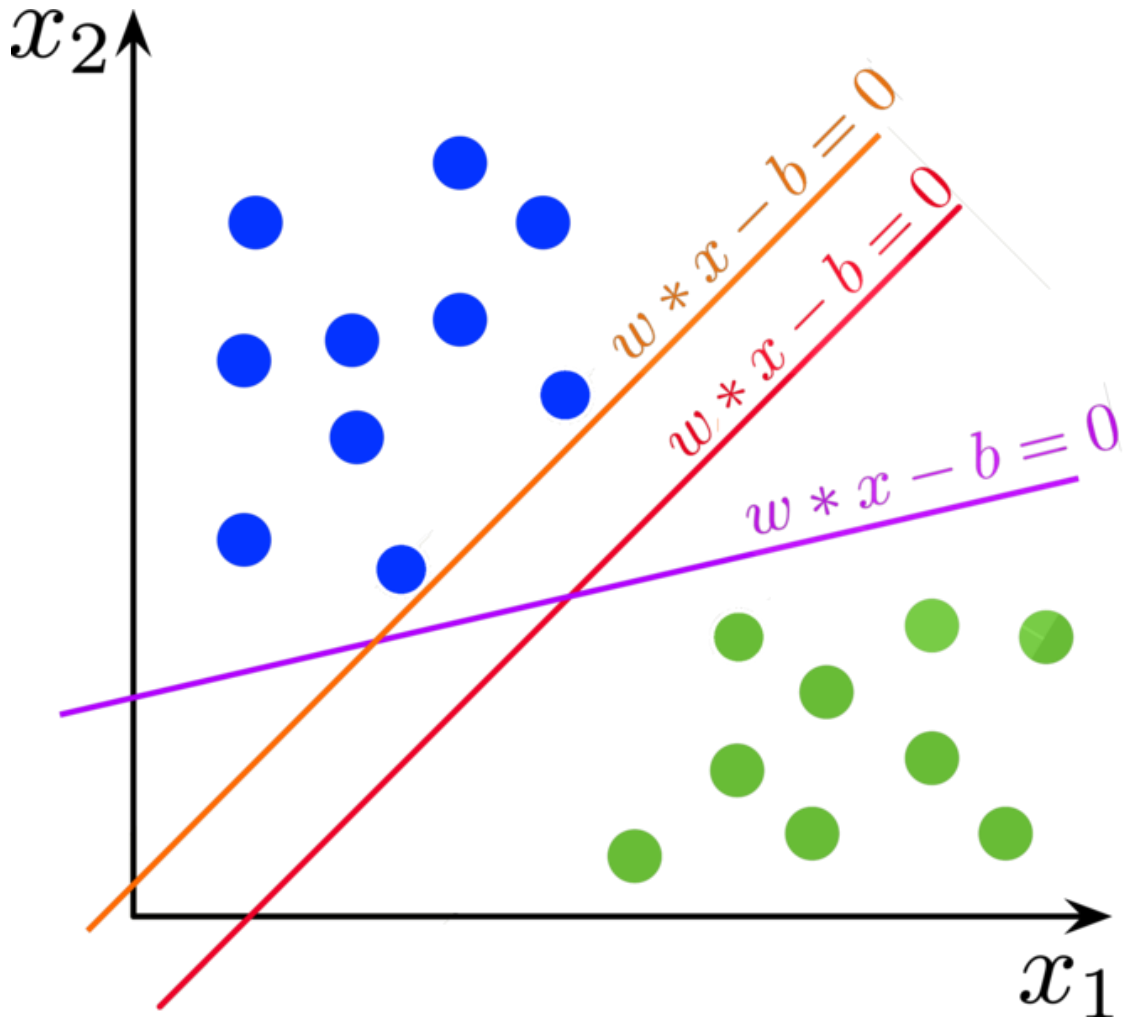
Метод опорных векторов (SVM support vector machine) находит оптимальное решение.

- ✓ Максимизирует расстояние между гиперплоскостью и трудными точками, близкими к границе раздела.
- ✓ Интуитивно: если нет точек около границы раздела, то нет и сложных (неопределённых) примеров.

Методы SVM принадлежит семейству линейных классификаторов и может также рассматриваться как специальный случай регуляризации по Тихонову.

- ✓ Особым свойством метода опорных векторов является непрерывное уменьшение эмпирической ошибки классификации и увеличение зазора, поэтому метод также известен как метод ***классификатора с максимальным зазором***.

Пример разделяющих гиперплоскостей



Метод опорных векторов

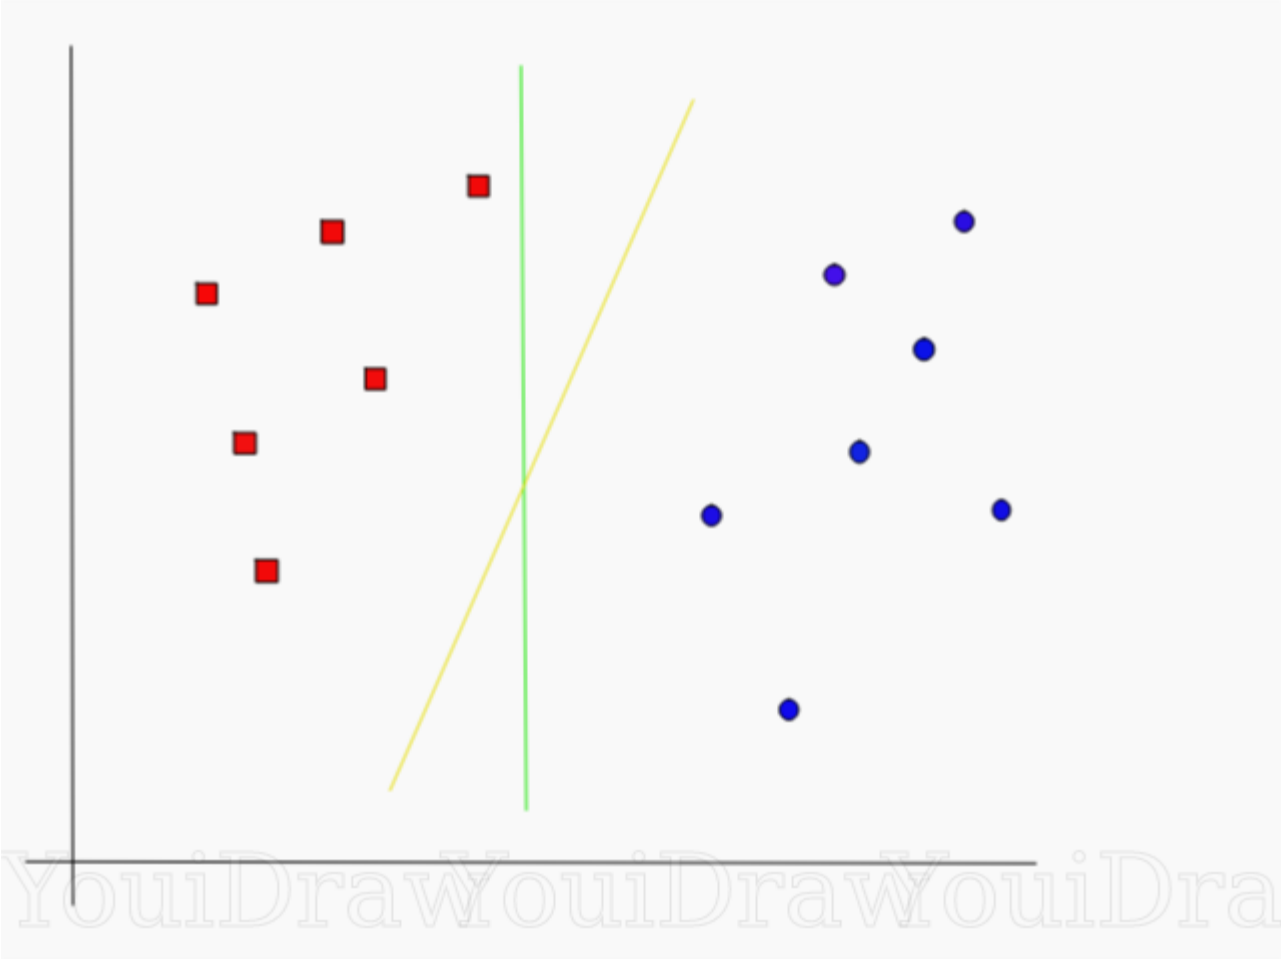
Основной задачей алгоритма является найти наиболее правильную линию, или гиперплоскость разделяющую данные на два класса. SVM это алгоритм, который получает на входе данные, и возвращает такую разделяющую линию.

Алгоритм SVM устроен таким образом, что он ищет точки на графике, которые расположены непосредственно к линии разделения ближе всего. Эти точки называются опорными векторами. Затем, алгоритм вычисляет расстояние между опорными векторами и разделяющей плоскостью. Это расстояние которое называется зазором. Основная цель алгоритма — максимизировать расстояние зазора. Лучшей гиперплоскостью считается такая гиперплоскость, для которой этот зазор является максимально большим.

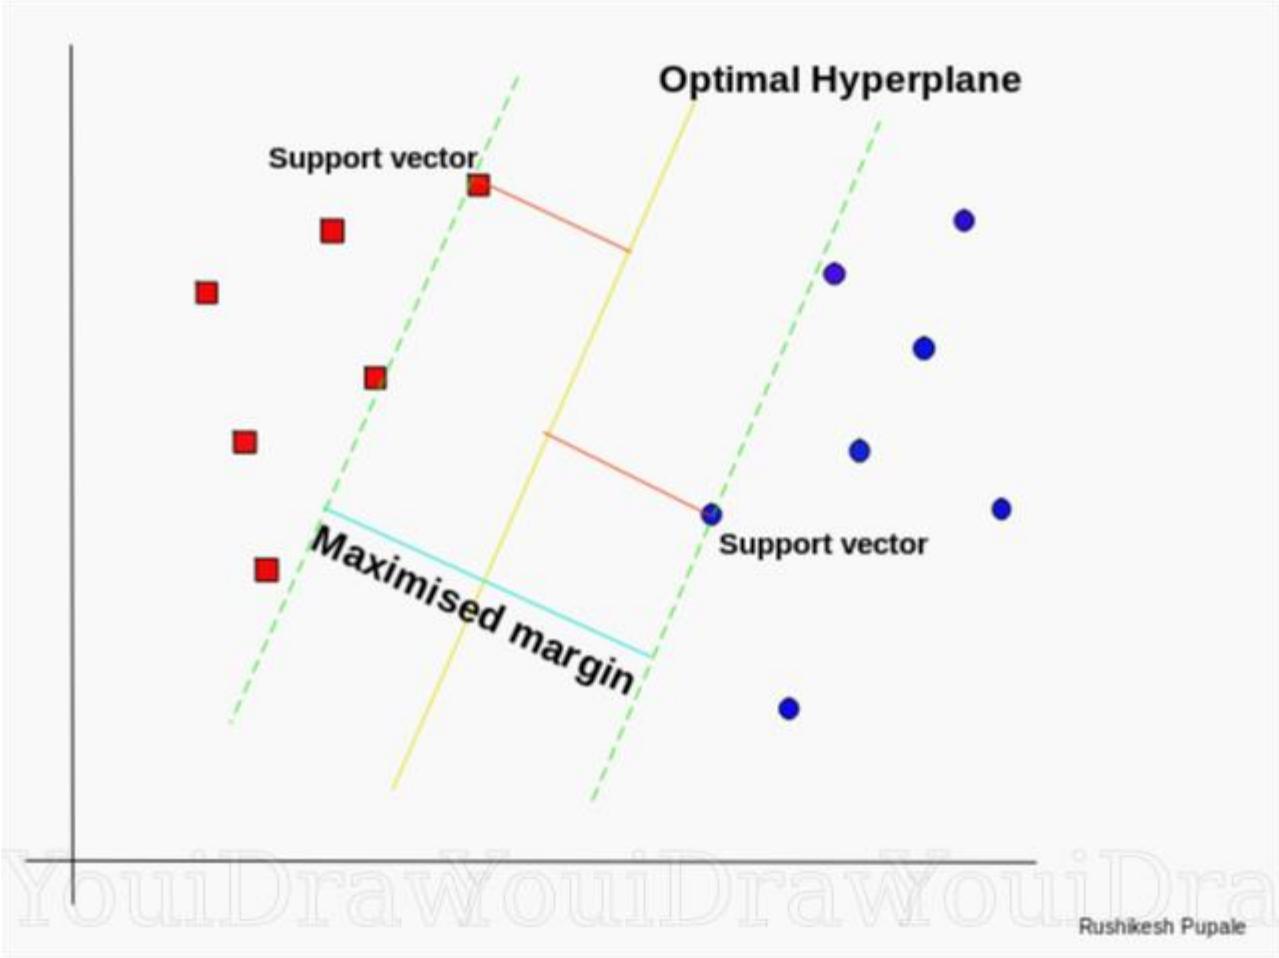
На слайдах 38 и 39 представлены пример с линейной разделимостью классов. В этом случае решение находится довольно просто. На слайде 39 можно интуитивно понять что желтая линия разделяет и соответственно классифицирует два класса лучше зеленой.

На слайде 40 представлен более сложный случай. Здесь классы линейно не разделимы.

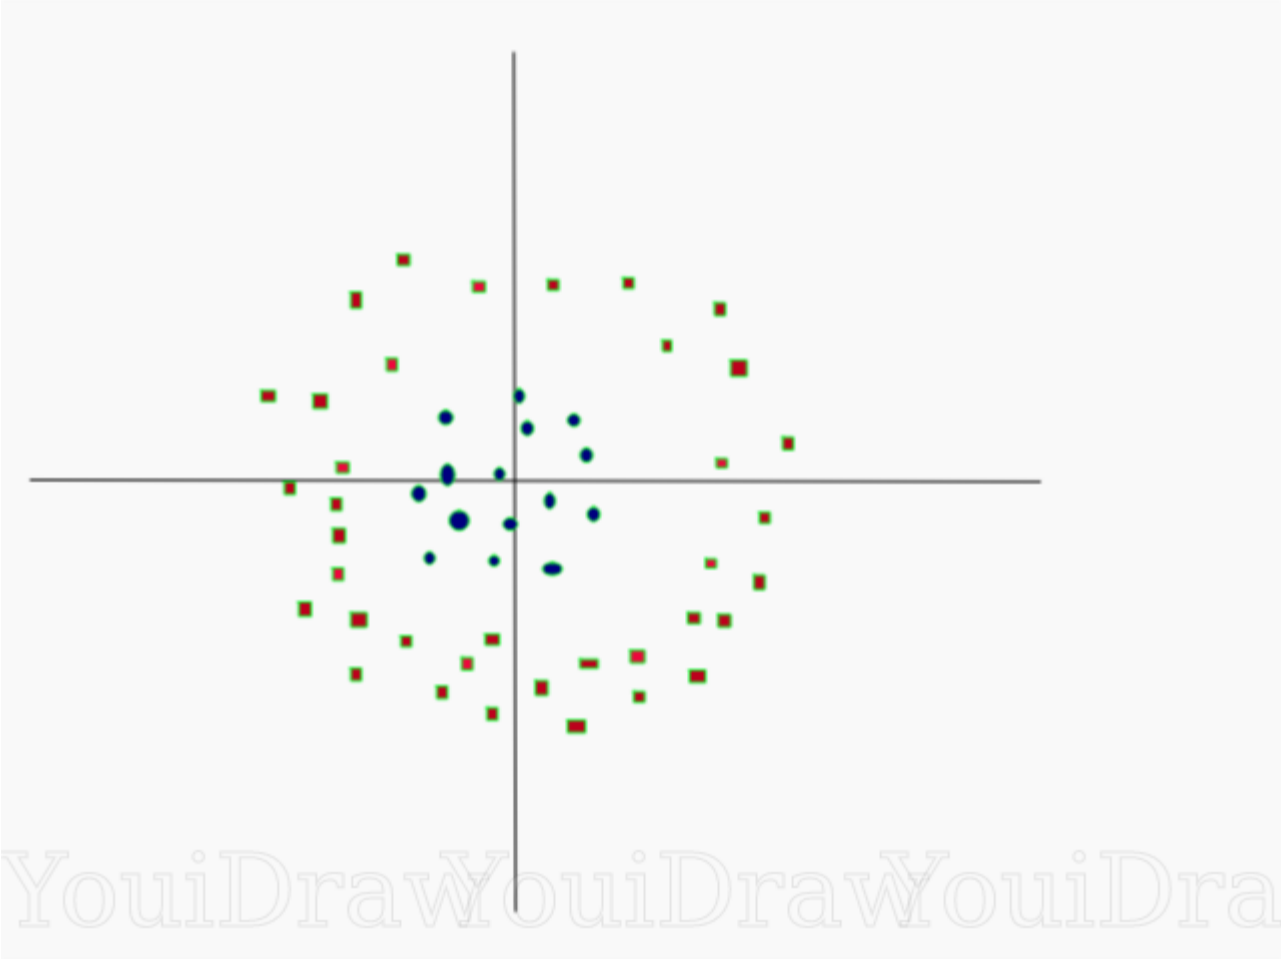
Линейное разделение классов



Пример построения разделяющей гиперплоскости



Нелинейное разделение классов



Нелинейная разделимость классов

Но, этот датасет можно разделить линейно, добавив дополнительное измерение, которое мы назовем осью Z. Представим, что координаты на оси Z регулируются следующим ограничением: Z=x+y,

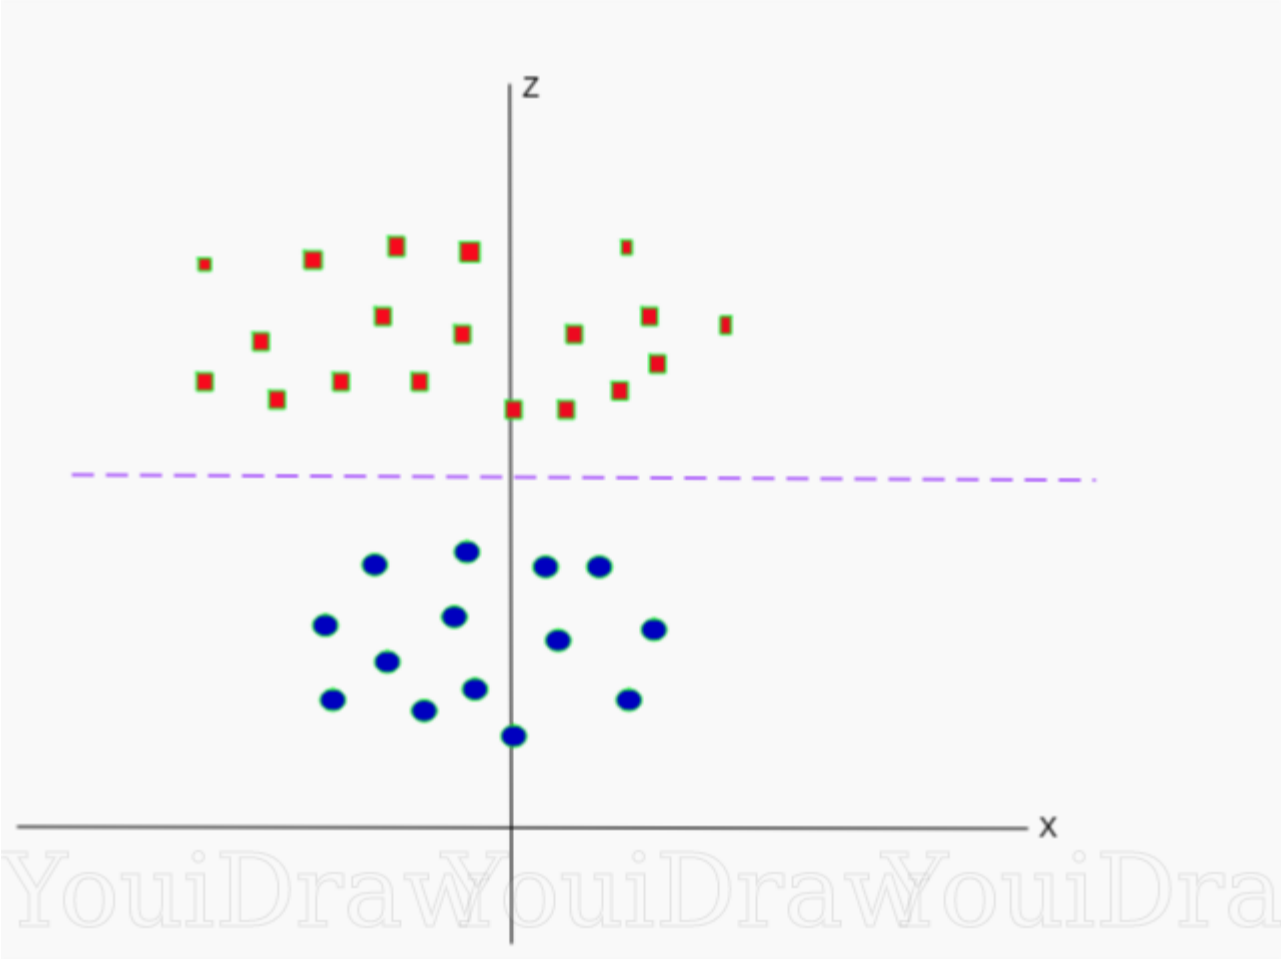
Таким образом, ордината Z представлена из квадрата расстояния точки до начала оси.

На сладе 42 приведена визуализация того же набора данных, на оси Z.

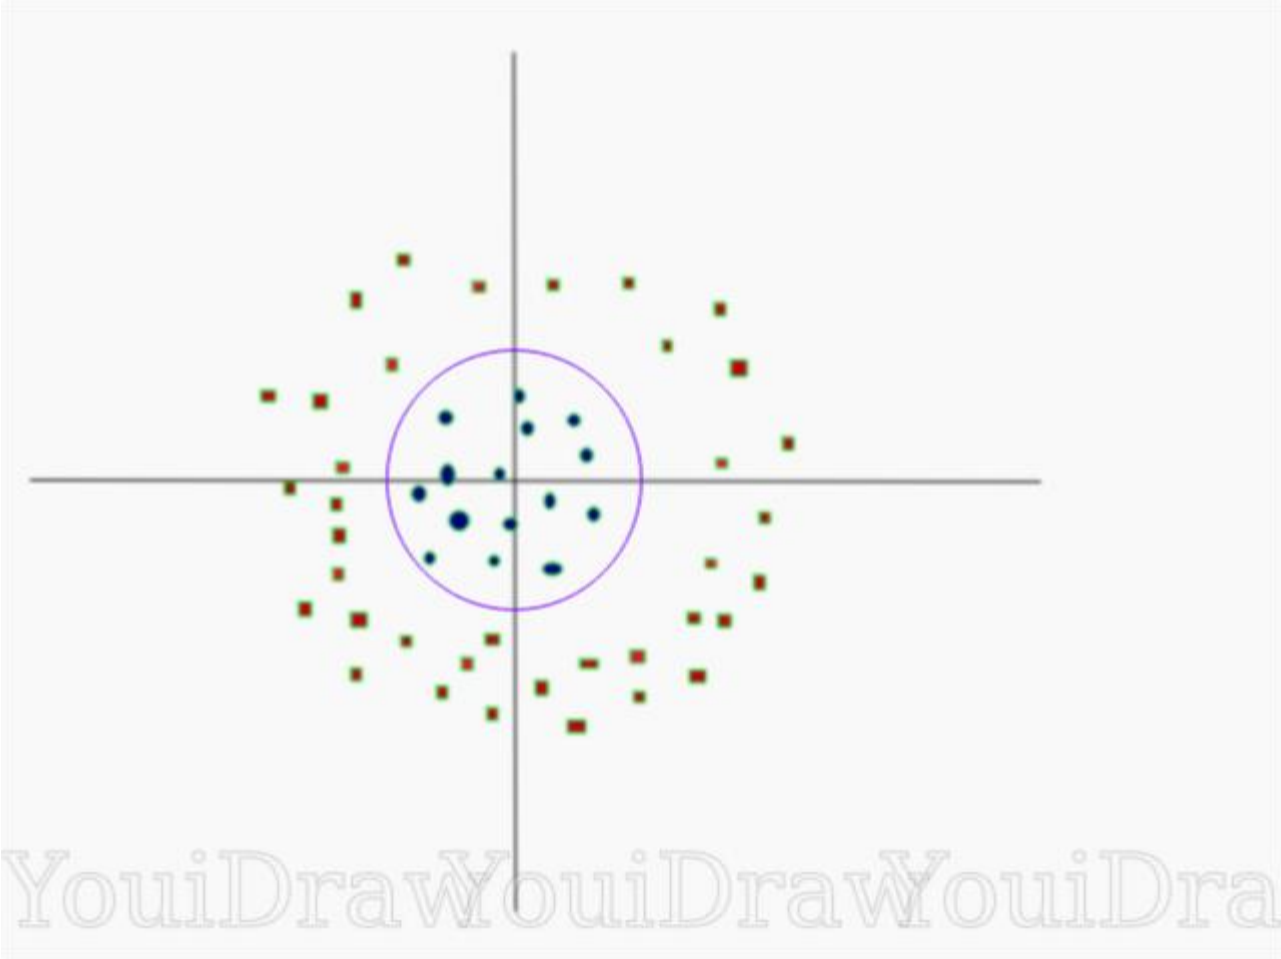
Теперь данные можно разделить линейно. Допустим пурпурная линия разделяющая данные z=k, где k константа. Если z=x+y, то следовательно и k=x+y — формула окружности. Таким образом, мы можем спроэцировать наш линейный разделитель, обратно к исходному количеству измерений выборки, используя эту трансформацию (слайд 43).

В результате, мы можем классифицировать нелинейный набор данных добавив к нему дополнительное измерение, а затем, привести обратно к исходному виду используя математическую трансформацию. Однако, не со всеми наборами данных можно с такой же легкостью произвести такую трансформацию. К счастью, имплементация этого алгоритма в библиотеке sklearn решает эту задачу за нас.

Нелинейное разделение классов



Нелинейное разделение классов



Теория Вапника-Червоненкиса

- Как оценить состоятельность метода?
- Как выбрать оптимальный, с точки зрения общего риска, алгоритм?
- Теория, предложенная русским математиком Владимиром Вапником (конец 60-х), для оценки способности к обучению различных моделей алгоритмов
- Основные результаты теории:
  - Оценка сложности (ёмкости) модели алгоритма
  - Оценка состоятельности через эмпирический риск и сложность модели

Владимир Наумович Вапник (род. 6 декабря 1936),

Алексей Яковлевич Червоненкис (7 сентября 1938 — 22 сентября 2014)

Теория распознавания образов (статистические проблемы обучения),
В. Н. Вапник, А. Я. Червоненкис. Издательство «Наука»,
Главная редакция физико-математической литературы, М., 1974, 416 стр.



Случай линейной разделимости

- Задача формулируется как поиск гиперплоскости максимально отдалённой от выпуклой оболочки классов.
- Такую гиперплоскость всегда можно записать в виде линейной комбинации «опорных векторов» - прецедентов, принадлежащих выпуклой оболочке.
- Задачу поиска такой гиперплоскости можно записать как задачу оптимизации:

$$w = \arg\max\left\{\frac{1}{\|w\|^2}\right\} = \arg\min\|w\|^2$$

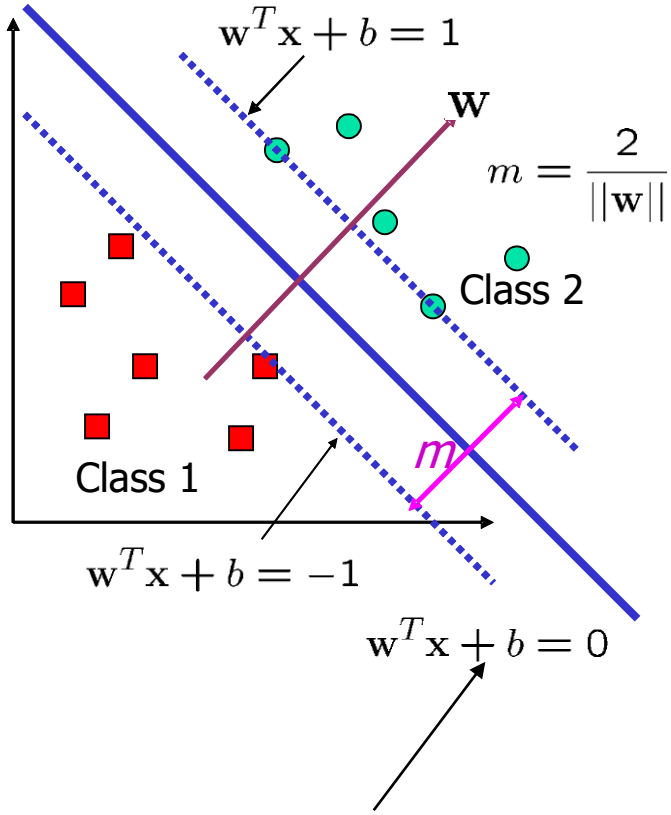
$$y_i\left(w \circ x_i - b\right) \geq 1$$

Решение:

$$w = \sum_{i=1}^{n} \lambda_i y_i x_i,$$

$$b = w \circ x_i - y_i,$$

Глобальный минимум находится методом квадратичного программирования

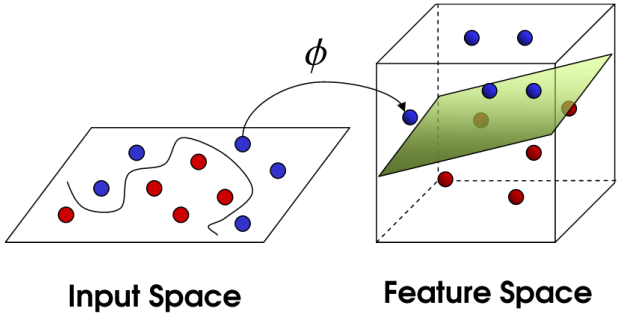


Чисто геометрическая задача

$\lambda_i > 0$ – *двойственные переменные*

Особенности метода при отсутствии линейной разделимости

- Алгоритм построения оптимальной разделяющей гиперплоскости, предложенный в 1963 году Владимиром Вапником и Алексеем Червоненкисом — **алгоритм линейной классификации**.
- Однако в 1992 году Бернхард Босер, Изабель Гийон и Вапник предложили способ создания нелинейного классификатора, в основе которого лежит переход от скалярных произведений к произвольным ядрам, так называемый **kernel trick**
  - ✓ Результирующий алгоритм крайне похож на алгоритм линейной классификации, с той лишь разницей, что каждое скалярное произведение в приведённых выше формулах заменяется **нелинейной функцией ядра** (скалярным произведением в пространстве с большей размерностью).
  - ✓ Ядровые преобразования можно быстро вычислять для скалярных произведений, даже при бесконечной размерности целевого пространства



$$u \circ v = (u \cdot v')^d$$

$$u \circ v = \exp\left(-\gamma \left\| u \cdot v \right\|^2\right), \gamma > 0$$

$$u \circ v = \exp\left(-\frac{\left\| u - v \right\|^2}{2\sigma^2}\right)$$

Характеристика SVM

+ Однозначность решения (глобальный минимум).
+ Теоретически доказана минимальность оценки общего риска (Вапник).
+ При помощи ядровых преобразований обобщается на случай сложных поверхностей.

– Требует подбора множества параметров (ядро, параметры ядра, штраф за ошибки).
– Теоретические оценки верны только для случая разделимости (схема со штрафами - эвристика).
– Очень чувствителен к нормализации данных!