НСиМО: ответы на вопросы по лекциям 1–3 (формулировки из слайдов)

Формулировки взяты дословно из слайдов лекций. Пропуски внутри слайдов отмечены «...». Опечатки слайдов не исправлены, они перечислены в конце.

---

1. Понятие машинного обучения. Параметры и гиперпараметры. Цель. Требования к данным

(лекция 1, слайды 19–22)

Понятие машинного обучения основано на понятии компьютерного моделирования объектов, явлений или процессов окружающего нас мира. Модель это совокупность законов, правил, описывающих поведение изучаемого процесса, явления, объекта. Модель может быть физической. Но чаще всего модель представляется в виде математических формул, ее так и называют математическая модель. ... Модели с параметрами называются параметрическими моделями и удобны для описания множества похожих объектов.

Каждый раз, подбирая параметры, надо передавать информацию модели, плохо или хорошо она описывает поведение объекта, такой процесс называют обучением. Если модель создается в компьютере, такой процесс называют машинным обучением. Модель должна вести себя также, как и объект, обучение это подбор параметров модели для достижения заданной цели – уменьшить ошибку модели, отклонение ее поведения от заданного поведения объекта. Идеал – нулевая ошибка – редко достижим, поэтому стремятся уменьшить ошибку до какой-то приемлемой величины.

Однако цель обучения не просто запомнить поведение объекта на измеренных данных, но в том, чтобы эта модель могла давать правдоподобные результаты и на других примерах, на которых ее не обучали.

Чтобы узнать, а как модель себя ведет на других данных (данные, на которых обучали, называют обучающими), такую модель тестируют, а данные на которых ее тестируют, называют тестовыми. ... Способность модели давать приемлемые результаты на тестовых данных называют обобщающей способностью, и именно повышение ее является целью обучения.

Различают параметры модели (обучаемые параметры) – те числа, которые изменяются в процессе обучения – и другие числа, которые описывают модель, но не меняются при обучении, а задаются до его начала (размер модели, число ее элементов и др.). Последние называют гиперпараметрами. Из-за сложности моделируемых объектов, наличия шумов, модели машинного обучения дают приближенные результаты. Если ошибки обучения и тестирования маленькие и приемлемые, то, скорей всего (но не гарантировано) модель хорошая и её можно использовать.

Модели с обучением очень требовательны к данным. Данные, на которых модель обучается и тестируется:

- должны быть разнообразны, на одинаковых данных, ничему новому модель не научится.
- должны быть непротиворечивы, когда данных много некоторые противоречия (ошибки) допустимы, модель с хорошей обобщающей способностью справится с этим, но таких

противоречий должно быть немного.
- должны быть релевантны задаче, действительно полностью описывать реальные моделируемые объекты. При измерениях неизбежны ошибки, если они маленькие, измеренные данные просто примерно описывают объект, но если большие – то невозможно узнать, что конкретное измеренное данное это ошибка или действительное описание объекта.
- тестовые данные должны отличаться от обучающих, иначе тест бесполезен.

---

2. Виды машинного обучения. Способы машинного обучения

(лекция 1, слайды 23–25)

В зависимости от того, какие именно данные доступны и какие цели преследует обучение, можно выделить несколько видов обучения:

1. **Обучение с учителем.** Данные представляются в виде пар примеров входов и эталонных выходов («указания учителя») модели. … Модель учится на этих парах, пытаясь подобрать свои параметры так, чтобы ее выходы совпали или были близки к эталонным. Это наиболее распространенный вид обучения. «Учитель» — это процесс, который собрал эти пары данных (это может быть и человек, и компьютер).
2. **Обучение без учителя или самообучение.** Бывает, что эталонные выходы модели неизвестны, но есть примеры входов. В этом случае модель может попытаться установить взаимосвязи между элементами входов, выделить какие-то общие черты. Для этого должен быть задан критерий такого выделения (явно или неявно). Это тоже популярный вид обучения, но более сложный, часто используется не сам по себе, а в дополнение к обучению с учителем.
3. **Обучение с подкреплением.** Бывает, что «учитель» сам не знает, что именно должно быть, но понимает какие действия обучаемого хорошие, а какие плохие. Перебирая возможные варианты действий модель будет получать штрафы или награды за действия и может научиться, какие действия приводят к наибольшей суммарной награде. … Такой подход используют, например, для создания ботов для компьютерных игр. Можно сочетать разные виды обучения между собой.

В зависимости от того, как часто поступают данные и как часто нужен результат, все перечисленные выше виды обучения могут выполняться несколькими способами:

- **Динамическое или онлайн обучение.** Как только данное поступило, необходимо сразу же, выдавать результат для него и доучивать модель (т.е. изменять параметры ее) для этого данного. Для большинства моделей с этим видом обучения важен порядок поступления данных: те же самые данные для той же самой модели, но представленные в другом порядке, могут привести к другому результату. Онлайн обучение хорошо тем, что оно быстрое, но обычно менее точное, и зависит от порядка поступления данных.
- **Отложенное или оффлайн обучение.** Здесь параметры модели изменяются только после того, как для всех данных будут рассчитаны выходы. Обычно порядок поступления данных не важен. Оффлайн обучение хорошо тем, что обычно не зависит от порядка поступления данных и более точное, но зато более медленное.
- Компромиссный вариант между онлайн и оффлайн обучением это **пакетное обучение**. Данные разбиваются на маленькие группы (пакеты, или по-английски batch), и параметры модели изменяются только после расчета пакета целиком. Изменяя размер пакета, сколько в него входит данных, можно балансировать между онлайн (размер пакета = 1) и оффлайн (размер пакета =

количеству всех данных) обучением. Сегодня это самый распространенный вариант организации обучения. … Вариант, когда модель может сама выбирать порядок поступления данных, называют **активное обучение**.

---

3. Задачи машинного обучения

(лекция 1, слайды 26–29)

Классификация. Имея набор примеров входов и список классов (названий, меток, номеров) нужно распределить примеры входов по этим классам. … Список возможных классов известен заранее и не бесконечен. Модель, которая решает такую задачу называется классификатором. Классификация может быть двухклассовой или бинарной, когда классов всего два, или многоклассовой, когда классов больше (одноклассовая классификация бессмыслена). … Обычно решается с помощью моделей с обучением с учителем.

Кластеризация. Имея только примеры входов, разбить их на группы (кластеры) так, чтобы внутри кластеров примеры были чем-то похожи, а примеры из разных кластеров чем-то отличались между собой. Обычно решается с помощью моделей с обучением без учителя, например, разделить звукозаписи по жанрам, это задача кластеризации. …

Регрессия. Имея набор примеров входов и соответствующих им выходов научиться выдавать выходы для других примеров входов с той же взаимосвязью входов и выходов. Отличается от классификации тем, что в классификации выход это класс (номер, название или другое его представление), т.е. дискретная величина, а в регрессии выход непрерывен (не дискретен). Классификация – частный случай регрессии, т.к. дискретную величину можно представить вариантом непрерывной. …

Прогнозирование. Зная, как изменялась какая-то величина до определенного времени, узнать, как она будет изменяться после. … Обычно сводится к задаче регрессии.

Оптимизация. Имея примеры данных и некоторую функцию, заданную на этих данных, найти такие данные, для которых функция принимает оптимальное (минимальное или максимальное) значение. … Обучение — это, по сути, оптимизация функции ошибки модели. Поэтому, так или иначе, все задачи сводятся к оптимизации некоторой функции. …

Другие задачи так или иначе сводятся к перечисленным выше:

- **ранжирование.** Отличается от регрессии или классификации тем, что выходы надо получить сразу на множестве примеров, после чего отсортировать их по значениям выходов. … Имеют значение только результаты сравнения этой функции на разных объектах …
- **сокращение размерности.** Входы часто являются объектами большой размерности (вектора, матрицы, массивы), однако не все ли элементы входов одинаково важны. Зачастую можно отбросить или преобразовать входы так, что их размерность будет меньше, но при этом наиболее важные черты данных сохранятся.

Основные классы задач по типам применяемых технологий: Машинное зрение (детектирование и подсчет объектов, семантическая сегментация, классификация изображений, обнаружение аномалий, дополненная реальность). Анализ голоса и текста (распознавания сотрудников, классификация документов, анализ скриптов сотрудников, работа с отзывами, генерация текстов). Прогнозирование и

предсказание (прогнозирование сбоев в работе оборудования, прогнозирование времени профилактического ремонта, прогнозирование товарных остатков, управление ценами).

---

4. Формальное определение модели машинного обучения

(лекция 1, слайд 35)

Пусть существуют два множества: Множество объектов – образов X. Множество ответов Y. Для построения модели требуется построить отображение $a : X \to Y$, такое что:

- Отображение воспроизводит на обучающей выборке требуемые ответы с некоторой вероятностью.
- Отображение способно к обобщению – аппроксимирует целевое отображение на всём множестве (проверяется на тестовой выборке).
- Возможны дополнительные ограничения целевой функции – гладкость, монотонность и т.д. (определяется задачей).

Для задачи классификации: Y – конечное множество. Бинарная классификация: $Y = 0, 1$. Классификация по нескольким классам: $Y = 1, ..., M$. Для задачи регрессии: $Y = \mathbb{R}$, действительные числа.

---

5. Формальное определение признака объекта. «Хорошие» и «плохие» векторы признаков

(лекция 1, слайды 36–37)

Объект, как правило, определяется вектором признаков. Признак – это результат измерения некоторой величины, отличительная характеристика объекта, качественная или количественная. Формально признаком называется отображение $f : X \to D_f$, где D_f – множество допустимых значений признака.

- Комбинация N признаков, представленная в виде вектора называется вектором признаков.
- N-мерное пространство, определяемое векторами признаков, называется пространством признаков.
- Объект — представляется N-мерными точками в пространстве признаков.

Что такое «хороший» вектор признаков? Качество вектора признаков связано с его разделяющей способностью для объектов из разных классов:

- Образцы из одного класса должны иметь подобные вектора признаков.
- Образцы из разных классов должны иметь различные вектора признаков.

Свойства, зависящие от векторов признаков (слайд 37, рисунки): Linear separability, Non-linear separability, Highly correlated features, Multi-modal; ниже показаны разбиения пространства на области R1, R2, R3 (простое) и R1–R4 (сложное).



Явного определения «плохого» вектора в лекции нет. Через приведённое определение это вектор, у которого образцы из одного класса не имеют подобных векторов, а образцы из разных классов не имеют различных.

---

6. Формальное определение модели машинного обучения с учителем. Недообучение и переобучение

(лекция 1, слайды 38, 40)

Пусть существуют два множества: Множество объектов – образов X. Множество ответов Y. Существует целевая функция $y^* : X \to Y$, значения которой известны только на конечном подмножестве объектов: $x1, ..., xn \subset X$. Существует совокупность пар «объект-ответ» $X^N = (x_i, y_i), i = 1..N$, где X^N – обучающая выборка.

Задача обучения заключается в том, чтобы по X^N выборке построить решающую функцию (отображение) $a : X \to Y$, которая бы приближала целевую функцию не только на объектах обучающей выборки, но и на всем множестве.

Недообучение (underfitting) — алгоритм обучения не обеспечивает достаточно малой величины средней ошибки на обучающей выборке. Недообучение возникает при использовании недостаточно сложных моделей.

Переобучение (overtraining, overfitting) — вероятность ошибки обученной модели на объектах тестовой выборки оказывается существенно выше, чем средняя ошибка на обучающей выборке.

На рисунке подписаны: излишнее обобщение, недообучение, underfitting; хорошая модель, good fit; излишняя избирательность, переобучение, overfitting.

---

7. Формальное определение модели алгоритма обучения

(лекция 1, слайд 41)

Требуется построить отображение (гипотезу) $a : X \to Y$. Пусть A – параметрическое семейство отображений $A = a(x, \gamma) | a : X \times \Gamma \to Y$, где Г – пространство допустимых значений параметра γ (пространство поиска). Будем выбирать отображение для решение задачи из A:

- Процесс выбора – обучение.
- Построение отображения $u : X^l \to a$ по обучающей выборке X^l – метод обучения.
- Обучение сводится к поиску точки в пространстве поиска Г.

---

8. Функционалы ошибок и метрики качества. Примеры функций ошибок

(лекция 1, слайды 43–46)

Обучение – это подбор параметров модели с целью уменьшения функции ошибки (по-английски loss). Сами функции ошибки разнообразны, зависят от задачи, которую требуется решить, используемой модели, данных, на которых проходит обучение.

Самой простой и распространенной функцией ошибки L, является функция квадрата расстояния между вектором Y выхода модели и указаний учителя D (эталонного выхода) на обучающих данных $X : L2 = (Y(X) - D(X))^2$. Если примеров данных несколько (для пакетного или оффлайн обучения), то берут среднее значение L между примерами. Любые другие расстояния, или, как их называют математики, меры, тоже могут использоваться в функциях ошибки (например модуль разности, а не квадрат, это так называемая L1 мера, L1 = |Y(X) − D(X)|. … Часто в функцию ошибки добавляют ограничения для модели, например, чтобы ее параметры были не очень велики.

Вообще, сложилась такая ситуация, что для подавляющего большинства моделей оптимизируется вовсе не то, что надо. Для задач классификации, функция ошибки обычно это средний квадрат расстояния между векторами выхода и указаний учителя. Но цель решения задачи классификации - уменьшить число неправильно классифицированных примеров. … К функции ошибки, которая будет использоваться для оптимизации параметров, предъявляют жесткие требования, например, дифференцируемости. Число ошибок — это не дифференцируемая функция, а квадрат расстояния – дифференцируемая. Тогда оценкой качества решения задачи будет являться метрика (по-английски metrics). Для одной задачи можно посчитать множество разных метрик. Именно метрики описывают качество решения задачи, а функция ошибки — это косвенное средство достижения заданных метрик.

Функция ошибки L: Y × Y → $\mathbb{R}$ характеризует отличие правильного ответа от ответа данного построенным алгоритмом:

- L(y', y) = [y' ≠ y] — индикатор ошибки,
- L(y', y) = |y' − y| — отклонение,
- L(y', y) = (y' − y)² — квадратичное отклонение,
- L(y', y) = [|y' − y| > ε] — индикатор существенного отклонения,
- y = y*(x) — целевая функция, y' = a(x) — алгоритм.

Алгоритм обучения обладает способностью к обобщению, если вероятность ошибки на тестовой выборке достаточно мала или хотя бы предсказуема, то есть не сильно отличается от ошибки на обучающей выборке.

Некоторые функции ошибок в Keras:

Функция	**Обозначение**
Средняя квадратическая ошибка / mean squared error	MSE
Средняя абсолютная ошибка / mean absolute error	MAE
Средняя абсолютная процентная ошибка / mean absolute percentage error	MAPE
Средняя квадратическая логарифмическая ошибка / mean squared logarithmic error	MSLE

Функция	Обозначение
Категориальная перекрестная энтропия / categorical crossentropy	CCE
Разреженная категориальная перекрестная энтропия / sparse categorical crossentropy	SCCE
Бинарная перекрестная энтропия / binary crossentropy	BCE
Категориальная верхняя граница / categorical hinge	CH
Пуассон / Poisson	PSS

9. Ошибки I и II рода. Матрица неточностей (confusion matrix)

(лекция 1, слайды 48–55)

> (???) **Пример расчёта вероятности.** Пусть некий тест на какую-нибудь болезнь имеет вероятность успеха 95%. 5% — вероятность как позитивной, так и негативной ошибки. Всего болезнь имеется у 1% респондентов. Пусть некий человек получил позитивный результат теста. Тест говорит, что он болен. С какой вероятностью он действительно болен? Пусть: t – результат теста; d – наличие болезни. По теореме Байеса P(d=1|t=1) = P(t=1|d=1)P(d=1) / (P(d=1)P(t=1|d=1) + P(d=0)P(t=1|d=0)) = 0,95·0,01 / (0,95·0,01 + 0,05·0,99). **Ответ: 16%.**

Допустим, существует «основной класс». Обычно, это класс, при обнаружении которого, предпринимается какое-либо действие; Например, при постановке диагноза основным классом будет «болен», а вторичным классом «здоров».

Измерения ошибки, как оценки «вероятности выдать неверный ответ», может быть не всегда достаточно: 16% ошибки при постановке диагноза может означать как и то что, 16% больных будут признаны здоровыми (и возможно умрут от отсутствия лечения), так и то, что 16% здоровых больными (и деньги на лечение будут потрачены зря). При неравнозначности ошибок для разных классов вводят понятие ошибки первого и второго рода и замеряют их по отдельности.

Ошибка первого рода равна вероятности принять основной класс за вторичный. Вероятность «промаха», когда искомый объект будет пропущен.

Ошибка второго рода равна вероятности принять вторичный класс за основной. Вероятность «ложной тревоги», когда за искомый объект будет принят «фон».

Особенно важно оценивать ошибки I и II рода раздельно при несбалансированности классов:

> (Лирическое отступление) Пусть $P(y = 1) = 0,01$; $P(y = -1) = 0,99$. Тогда при нулевой ошибке II рода и ошибке I рода $P(a(x) = -1|y = 1) = 0,5$ общая ошибка всего лишь $P(a(x) \neq y) = 0,005$.

Анализ ошибок классификации. Задача классификации на 2 класса $y_i \in \{-1; 1\}$. Алгоритм классификации $a(x_i) \in \{-1; 1\}$.

	Ответ классификатора	Правильный ответ
TP, True Positive	$a(x_i) = +1$	$y_i = +1$
TN, True Negative	$a(x_i) = -1$	$y_i = -1$
FP, False Positive (ошибка I рода)	$a(x_i) = +1$	$y_i = -1$
FN, False Negative (ошибка II рода)	$a(x_i) = -1$	$y_i = +1$

Основной метрикой для такой задачи является **матрица неточностей (confusion matrix)**, у которой одно измерение отвечает за классы, посчитанные моделью, второе за истинные классы из данных, а в клетках указывается количество соответствующих (или доля) примеров.

Матрица ошибок (слайд 53):

	y=1 (правильный ответ)	y=0 (правильный ответ)
Ответ классификатора $y^* = 1$	True Positive (TP)	False Positive (FP)
Ответ классификатора $y^* = 0$	False Negative (FN)	True Negative (TN)

Возможно всего четыре ситуации:

- был объект основного класса и модель приняла его за объект основного класса, это верное распознавание, обозначается как **TP**.
- был объект вторичного класса и модель так и ответила, это тоже верное распознавание, обозначается как **TN**.
- был объект основного класса, но модель сказала, что это объект вторичного класса, это ошибка, обозначается как **FP** (ложная тревога, первого рода).
- был объект вторичного класса, но модель сказала, что был объект основного класса, это тоже ошибка, обозначается как **FN** (пропуск, второго рода).

Матрица ошибок confusion_matrix() в scikit-learn: Одним из самых наиболее развёрнутых способов оценки качества классификации является применение матрицы ошибок. Матрица ошибок представляет собой квадратную таблицу, в которой отображается количество предсказанных и фактических классов для классификационной модели. В этой матрице строки представляют истинные классы (реальные метки), а столбцы представляют предсказанные классы (метки, которые предсказала модель). Размер матрицы соответствует количеству классов. Обычно для бинарной классификации она выглядит так: TP (True Positive) – истинно положительные примеры; TN (True Negative) – истинно отрицательные примеры; FP (False Positive) – ложноположительные примеры; FN (False Negative) – ложноотрицательные примеры.

---

10. Метрики оценки качества решения задачи классификации

(лекция 1, слайды 56–58)

Матрица несет в себе всю информацию о качестве модели, в идеале элементы вне главной диагонали (ошибки) равны нулю. Но матрица сложна для понимания человеком, поэтому на основе этой матрицы считают множество других метрик.

Доля правильных ответов алгоритма среди общего количества ответов часто задается в виде меры аккуратности: **accuracy = (TP + TN) / (TP + TN + FP + FN)**. Особенность данной метрики заключается в том, что она не учитывает случай с несбалансированными данными в выборке. В таком случае следует либо использовать сбалансированную выборку данных, либо изменить метрику оценки качества классификации.

Для оценки в пределах класса используются такие метрики, как точность и полнота. Точность показывает долю объектов, верно рассчитанную алгоритмом классификации среди всех, рассчитанных им как положительные: **precision = TP / (TP + FP)**. Полнота показывает способность алгоритма находить данный класс вообще, и описывается формулой: **recall = TP / (TP + FN)**. Точность и полнота применимы даже в условиях несбалансированных выборок. На основании этих оценок можно рассчитать их взвешенное среднее. Recall демонстрирует способность алгоритма обнаруживать данный класс вообще, а precision — способность отличать этот класс от других классов.

FPR – показывает уровень неверных позитивных ответов: **FPR = FP / (FP + TN)**. TPR – показывает уровень верных позитивных ответов: **TPR = TP / (TP + FN)**.

F-мера — среднее гармоническое precision и recall: **$F\beta = (1 + \beta^2) \cdot precision \cdot recall / (\beta^2 \cdot precision + recall)$**. β в данном случае определяет вес точности в метрике. F-мера достигает максимума при полноте и точности, равными единице, и близка к нулю, если один из аргументов близок к нулю. В случае задач с несбалансированными классами, которые превалируют в реальной практике, часто приходится прибегать к техникам искусственной модификации выборок для выравнивания соотношения классов.

---

11. ROC кривая. Интегральный показатель прогностической эффективности признака (AUC)

(лекция 1, слайды 59–61)

ROC кривая – Receiver Operating Characteristic curve. Кривая, отражающая зависимость TPR от FPR при плавном изменении порога признака. С помощью ROC можно анализировать возможность текущего решения соответствовать требованиям.

Форма ROC кривых (оси SE и 1 − SP): Признак не работает; Идеальный признак; 1-ый тест лучше, чем 2-ой.

Интегральный показатель прогностической эффективности признака: **AUC** - это площадь под ROC-кривой (Area Under Curve). Вероятность того, что значение признака у случайно выбранного объекта относящегося к классу больше, чем у случайно выбранного не относящегося.

AUC	
0,5	Случайный классификатор
0,5–0,6	Плохой классификатор
0,6–0,7	Средний классификатор
0,7–0,8	Хороший классификатор
>0.8	Отличный классификатор

---

12. Метрики оценки качества решения задачи регрессии

(лекция 1, слайды 62–64)

Средняя квадратичная ошибка MSE, один из наиболее распространённых показателей для оценки регрессионных моделей, в том числе и в задачах прогнозирования. MSE измеряет среднеквадратичную ошибку прогнозов. Для каждой точки вычисляется квадратная разница между прогнозами и целью, а затем усредняются эти значения:

$$MSE = \frac{1}{N} \cdot \sum (y_i - y_i')^2.$$

Чем выше это значение, тем хуже модель. Ошибка никогда не бывает отрицательной, для идеальной модели это будет ноль.

Среднеквадратическая ошибка RMSE, это квадратный корень из MSE:

$$RMSE = \sqrt{\frac{1}{N} \sum (y_i - y_i')^2)}.$$

RMSE служит для объединения величин ошибок в прогнозах для различных точек данных в единую меру прогноза. RMSE — это мера точности, позволяющая сравнивать ошибки прогнозирования различных моделей для конкретного набора данных, а не между наборами данных, поскольку она зависит от масштаба. RMSE всегда неотрицательна, и значение 0 указывает на идеальное соответствие данным.

Средняя абсолютная ошибка MAE это линейная оценка, показывающая что все индивидуальные различия взвешены одинаково в среднем:

$$MAE = (\frac{1}{N}) \sum |y_i - y_i'|.$$

Данная оценка является более робастной чем MSE.

Средняя абсолютная ошибка MAPE – это та же ошибка MAE выраженная в процентах. Данная оценка применяется для временных рядов, фактические значения которых значительно больше 1. Для каждого объекта абсолютная ошибка делится на целевое значение, что дает относительную ошибку:

$$MAPE = (\frac{1}{N}) \cdot \sum \frac{|y_i - y_i'|}{|y_i|} \cdot 100\%.$$

Считается, что точность модели хорошая, если среднее значение относительной погрешности не превышает 5%, удовлетворительная, если среднее значение относительной погрешности не превышает 15%, и неудовлетворительная, если среднее значение относительной погрешности больше 15%.

---

13. Методы экспериментальной оценки качества алгоритмов обучения

(лекция 1, слайды 65–71)

Для конкретной задачи, желательно получить точные количественные оценки качества работы, поэтому используются экспериментальные методы: удерживание (валидация); скользящий контроль (кросс-валидация); стратифицированная кросс-валидация.

Валидация модели — это важный этап в процессе машинного обучения, который помогает оценить её производительность и обеспечить корректность предсказаний на новых данных. …

Удерживание - это разделение данных на обучающую и валидационную (тестовую) выборки. Для моделей машинного обучения (кроме моделей нейронных сетей) понятия валидационной и тестовой выборки часто совпадают. Сначала набор данных разделяется на две части: обучающую (training) и тестовую (test). Модель обучается на одной части данных, а затем оценивается на другой. … Для обучения и тестирования нейронных сетей набор данных разделяют не на 2, а на 3 части: обучающую, проверочную (валидационную) и тестовую.

Достоинство метода: быстро и просто рассчитывается. Недостатки метода: некоторые «сложные» примеры могут полностью попасть в только одну из выборок и тогда оценка ошибки будет смещённой; можно повторить несколько раз и усреднить результат. Это позволяет частично избавиться от «сложных» примеров.

Кросс-валидация (cross-validation) или скользящий контроль – это разделение данных на несколько частей (например, 5 или 10). Модель последовательно обучается на каждой части, а тестируется на остальных. Достоинство метода: в пределе равен теоретической ошибке; каждый пример будет один раз присутствовать в контрольной выборке. Недостатки метода: обучающие выборки будут сильно перекрываться (чем больше сегментов, тем больше перекрытие); если одна группа «сложных» примеров попала полностью в один сегмент, то оценка будет смещенной. Результат считается как средняя ошибка по всем итерациям.

Стратифицированная кросс-валидация. Если целевая переменная имеет неравномерное распределение классов (например, в задачах классификации), важно сохранить это соотношение при разделении на обучающие и тестовые данные. Стратифицированная кросс-валидация решает эту задачу, распределяя данные пропорционально классам в каждом разбиении. … Модель обучается и тестируется на каждом разбиении, что обеспечивает более точную оценку производительности для несбалансированных данных.

---

14. Метод k-ближайших соседей (K-Nearest Neighbors). Метрики расстояний. Достоинства и недостатки

(лекция 2, слайды 9, 17, 20, 21)

Этот метод работает с помощью поиска кратчайшей дистанции между тестируемым объектом и ближайшими к нему классифицированными объектами из обучающего набора. Классифицируемый объект будет относится к тому классу, к которому принадлежит ближайший объект набора.

K-nearest neighbor – kNN. Метод решения задачи классификации, который относит объекты к классу, которому принадлежит большинство из k его ближайших соседей в многомерном пространстве признаков. Число k – это количество соседних объектов в пространстве признаков, которое сравнивается с классифицируемым объектом. Использование только одного ближайшего соседа (1NN) ведёт к ошибкам из-за: нетипичных примеров; ошибок в ручной привязке единственного обучающего примера. Более устойчивой альтернативой является k наиболее похожих примеров и определение большинства. Величина k типично нечётная: 3, 5.

Нормализация и вычисление расстояния. Методы нормализации признаков объектов:

- Минимаксная нормализация: $x^* = \frac{(x - x_min)}{(x_max - x_min)}$
- Нормализация с помощью стандартного отклонения: $x^* = \frac{(x - x_mean)}{\sigma_x}$, где σ_x - стандартное отклонение.

Метрики расстояния:

- Евклидово расстояние: $\rho(x1, x2) = \sqrt{\sum_{i=1..n}(x_{1,i} - x_{2,i})^2}$
- Расстояние Чебышёва: $\rho(x1, x2) = max_{i=1..n}(|x_{1,i} - x_{2,i}|)$
- Манхэттенское расстояние: $\rho(x1, x2) = \sum_{i=1..n}|x_{1,i} - x_{2,i}|$

Достоинства:

- Программная реализация относительно проста.
- Возможность модификации алгоритма.
- Алгоритм устойчив к аномальным выбросам.
- Возможность интерпретации результатов работы алгоритма.

Недостатки:

- Набор данных, используемый для алгоритма, должен быть репрезентативным.
- Необходимость хранить обучающую выборку целиком.
- В простейших случаях метрические алгоритмы имеют крайне бедный набор параметров, что исключает возможность настройки алгоритма по данным.
- Затраты в производительности велики, поскольку необходимо вычислить расстояния между каждым экземпляром и всеми пробными экземплярами.

---

15. Деревья решений. Случайный лес. Достоинства и недостатки

(лекция 2, слайды 26, 29–35, 37, 39–42)

Деревья решений – способ представления правил в иерархической, последовательной структуре. Определение: Дерево решений – представленный в виде связного ациклического графа план, при помощи которого оценивается значение целевого атрибута объекта по набору значений независимых атрибутов.

Дерево принятия решений (также называют деревом классификации или регрессионным деревом) — средство поддержки принятия решений, использующееся в машинном обучении, анализе данных и статистике. Структура дерева представляет собой «листья» и «ветки». На рёбрах («ветках») дерева решения записаны признаки, от которых зависит целевая функция, в «листьях» записаны значения целевой функции, а в остальных узлах — признаки, по которым различаются случаи. Чтобы классифицировать новый случай, надо спуститься по дереву до листа и выдать соответствующее значение. …

Двоичное дерево. Узлы – помечены некоторым предикатом $\beta : X \to \{true, false\}$. Обычно, используются пороги по проекциям на оси координат (на элементы вектора признаков). Связи – помечены. Листья – помечены ответами из Y. Внутренний узел представляет разбиение множества возможных значений той или иной независимой переменной. Атрибуты, соответствующие внутренним узлам дерева – атрибуты расщепления (прогнозирующие атрибуты). Каждая ветвь от внутреннего узла

отмечается предикатом расщепления. Информация об атрибутах и предикатах расщепления в узле – критерий расщепления.

Модель алгоритма обучения.

Дана обучающая выборка:

1. Выбираем целевой атрибут.
2. Выбираем критерий расщепления.
3. Разделяем обучающую выборку.
4. Исключаем атрибут расщепления из выборки.
5. Для всех полученных подвыборок переходим на шаг 2.

Модель классификатора.

Выходом классификатора $a(x)$ является значение у листа, полученного при обходе: Начинаем от корня. Переходим в тот узел, в который ведёт связь помеченная значением предиката в текущем узле. Заканчиваем, попав в лист. Лист определяет собой область пространства X.

Если зависимая переменная принимает дискретные значения – задача классификации. Если непрерывные – задачу регрессии (численного прогнозирования).

Процесс заключается в последовательном, рекурсивном разбиении обучающего множества на подмножества с применением решающих правил в узлах. … Процесс разбиения продолжается до тех пор, пока все узлы в конце всех ветвей не будут объявлены листьями. Объявление узла листом может произойти естественным образом (когда он будет содержать единственный объект, или объекты только одного класса), или по достижении некоторого условия остановки, задаваемого пользователем (например, минимально допустимое число примеров в узле или максимальная глубина дерева).

Алгоритмы построения деревьев решений относят к категории так называемых жадных алгоритмов. Жадными называются алгоритмы, которые допускают, что локально-оптимальные решения на каждом шаге (разбиения в узлах), приводят к оптимальному итоговому решению. В случае деревьев решений это означает, что если один раз был выбран атрибут, и по нему было произведено разбиение на подмножества, то алгоритм не может вернуться назад и выбрать другой атрибут, который дал бы лучшее итоговое разбиение. … Основные этапы: Выбор атрибута, по которому будет производиться разбиение в данном узле (атрибута разбиения). Выбор критерия остановки обучения. Выбор метода отсечения ветвей (упрощения). Оценка точности построенного дерева.

Алгоритмы обучения:

- **ID3 (Iterative Dichotomizer 3)** — алгоритм позволяет работать только с дискретной целевой переменной, поэтому деревья решений, построенные с помощью данного алгоритма, являются классифицирующими. Число потомков в узле дерева не ограничено. Не может работать с пропущенными данными.
- **C4.5** — усовершенствованная версия алгоритма ID3, в которую добавлена возможность работы с пропущенными значениями атрибутов …
- **CART (Classification and Regression Tree)** — алгоритм обучения деревьев решений, позволяющий использовать как дискретную, так и непрерывную целевую переменную, то есть решать как задачи классификации, так и регрессии. Алгоритм строит деревья, которые в каждом узле имеют только два потомка.

Критерии остановки алгоритма. Если «рост» дерева не ограничить, то в результате будет построено сложное дерево с большим числом узлов и листьев. Проблема переобучения — точное распознавание примеров, участвующих в обучении и полная несостоятельность на новых данных. Переобученные деревья имеют очень сложную структуру, и поэтому их сложно интерпретировать. Ранняя остановка — алгоритм будет остановлен, как только будет достигнуто заданное значение некоторого критерия, например процентной доли правильно распознанных примеров. … Ограничение глубины дерева — задание максимального числа разбиений в ветвях, по достижении которого обучение останавливается. … Задание минимально допустимого число примеров в узле — запретить алгоритму создавать узлы с числом примеров меньше заданного (например, 5).

Случайный лес. Метод случайного леса (англ. random forest) — алгоритм машинного обучения (предложен в 2001 г.), сочетает в себе две основные идеи: метод бэггинга (решающие деревья обучаются независимо и параллельно, а затем их результаты просто усредняются) и метод случайных подпространств (разбиение объектов в вершине случайного дерева ищется среди случайного подмножества признаков, а обучение каждого дерева происходит на выборке, полученной с помощью операции бутстрепа - случайной генерации выборок). Метод основан на использовании большого (комитета) ансамбля решающих деревьев, каждое из которых само по себе даёт очень невысокое качество классификации, но за счёт их большого количества результат улучшается.

Алгоритм обучения: Обучающая выборка состоит из N образцов, размерность пространства признаков равна M. Построение ансамбля деревьев: Генерируется случайная подвыборка размером N из обучающей выборки. Некоторые образцы попадут в неё два или более раза, тогда как в среднем $N \cdot \left(1 - \frac{1}{N}\right)^N$ образцов не войдут в подвыборку. Формируется решающее дерево, классифицирующее образцы данной подвыборки, причём в ходе создания очередного узла дерева случайным образом выбирается m признаков из всех M признаков. Выбор наилучшего из этих m признаков может осуществляться различными способами. Дерево строится до полного исчерпания подвыборки и не подвергается процедуре прунинга (англ. Pruning) — отсечение ветвей. Классификация объектов проводится путём голосования: каждое дерево комитета относит классифицируемый объект к одному из классов, а побеждает класс, за который проголосовало наибольшее число деревьев. Оптимальное число деревьев подбирается таким образом, чтобы минимизировать ошибку классификатора на тестовой выборке. В случае её отсутствия, минимизируется оценка ошибки на не вошедших в набор образцах.

Характеристика деревьев решений. Достоинства: Просты в понимании и интерпретации. Не требуют подготовки данных. Используют модель «белого ящика». Позволяют оценить модель при помощи статистических тестов. Дают возможность извлекать из базы данных правила на естественном языке. Позволяют создавать классификационные модели в тех областях, где аналитику достаточно сложно формализовать знания. Алгоритм конструирования дерева решений не требует от пользователя выбора входных атрибутов. Быстро обучаются. Недостатки: Проблема получения оптимального дерева решений бывает NP-полной. Могут появиться слишком сложные конструкции, которые при этом недостаточно полно представляют данные. Существуют концепты, которые сложно понять из модели, так как модель описывает их сложным путём. Для данных, которые включают категориальные переменные с большим набором уровней, больший информационный вес присваивается тем атрибутам, которые имеют большее количество уровней.

Характеристика случайного леса. Достоинства: Высокая точность предсказания, которая сравнима с результатами градиентного бустинга. Эффективная обработка данных с большим числом признаков и классов. Нечувствительность к масштабированию (и вообще к любым монотонным преобразованиям)

значений признаков. Использует методы оценивания значимости отдельных признаков в модели. Внутренняя оценка способности модели к обобщению (тест по неотобранным образцам). Высокая параллелизуемость и масштабируемость. Недостатки: Большой размер получающихся моделей. Очень трудоемкий процесс прогнозирования по сравнению с другими алгоритмами. Алгоритм склонен к переобучению на зашумленных данных. В отличие от более простых алгоритмов, результаты случайного леса сложнее интерпретировать.

---

16. Формула Байеса. Наивный байесовский классификатор. Достоинства и недостатки

(лекция 2, слайды 47–53 и последние два слайда)

Условная вероятность.

Определение. Пусть $P(A) > 0$. Условной вероятностью $P(B/A)$ события B при условии, что событие A наступило, называется число $P(B/A) = \frac{P(AB)}{P(A)}$. Условная вероятность удовлетворяет всем аксиомам вероятности. В частности, $0 \leq P(B/A) \leq 1$, $P(A/A) = 1$.

Независимые события.

Определение. События A и B называются независимыми, если $P(AB) = P(A)P(B)$.

Определение. Пусть $P(A) > 0$ и $P(B) > 0$. Событие A не зависит от B, если $P(A/B) = P(A)$.

Полная группа событий.

События $H_1, H_2, ..., H_n$ образуют полную группу, если они

1. попарно несовместны
2. в результате эксперимента обязательно какое-либо одно из них наступит. $P(HiHj) = 0, i \neq j$; H_i – гипотезы.

Формула полной вероятности.

Теорема. Если события $H_1, H_2, ..., H_n$ образуют полную группу, то для любого события A справедлива формула

$$P(A) = P(H_1)P(A/H_1) + ... + P(H_n)P(A/H_n) = \sum_{i=1..n} P(H_i)P(A/H_i).$$

Формула Байеса.

Теорема. Пусть события $H1, H2, ..., Hn$ образуют полную группу. Пусть событие A наступило ($P(A) > 0$). Тогда вероятность того, что при этом была реализована гипотеза (наступило событие) H_k вычисляется по формулой

$$P(H_k/A) = \frac{P(H_k)P(A/H_k)}{P(A)} = \frac{P(H_k)P(A/H_k)}{\sum_{i=1..n} P(H_i)P(A/H_i)}.$$

Формула Байеса позволяет переоценить вероятности гипотез после того, как проведено испытание, в результате которого произошло событие A.

Формула Байеса. Частный случай.

Рассмотрим события H и $\bar{H}$, они образуют полную группу. Пусть событие A наступило ($P(A) > 0$). Тогда вероятность того, что при этом была реализована гипотеза H вычисляется по формуле

$$P(H/A) = \frac{P(H)P(A/H)}{P(A)} = \frac{P(H)P(A/H)}{P(H)P(A/H)+P(\bar{H})P(A/\bar{H})}.$$

Наивный байесовский классификатор.

Наивный байесовский классификатор — простой вероятностный классификатор, основанный на применении Теоремы Байеса со строгими (наивными) предположениями о независимости. Предположения: Известна функция правдоподобия: $P(x|y)$. Известны априорные вероятности: $P(y)$, $P(x)$. Принцип максимума апостериорной вероятности:

$$a(x) = argmax_{y \in Y} P(y|x) = argmax_{y \in Y} (P(x|y)P(y)/P(x)),$$

где $P(x|y)$ – правдоподобие (условная вероятность наблюдения), $P(y)$ – вероятность класса, $P(x)$ – вероятность наблюдения.

Алгоритм:

1. Для каждой гипотезы вычислить апостериорную вероятность.
2. Выбрать гипотезу с максимальной апостериорной вероятностью.

Особенности наивного байесовского классификатора:

1. Нужно знать функцию правдоподобия и априорные вероятности.
2. Отсутствуют априорные причины верить, что одна из гипотез более вероятна чем другая (наивность).
3. Отвечает на вопрос – Какова наиболее вероятная гипотеза при имеющихся данных?
4. Надо ответить на вопрос – Какова наиболее вероятная классификации нового примера при имеющихся данных?

> Явных достоинств и недостатков наивного байесовского классификатора в лекциях нет.

---

17. Признаки и разбиение пространства. Разбиение пространства как задача классификации

(лекция 3, слайды 6–8)

Задача классификации: определить вектор $\vec{x}$ в один из K классов Y. Ищем линейную дискриминантную функцию определяющую разделяющую поверхность между классами $y(x) = w^T x + w_0$. Это гиперплоскость, и w – нормаль к ней. Расстояние от начала координат до гиперплоскости равно $-\frac{w_0}{||w||}$. $y(x)$ связано с расстоянием до гиперплоскости: $d = \frac{y(x)}{||w||}$.

Разбиение пространства, как задача классификации (слайд 7, рисунок):

Области $R1(y > 0)$ и $R2(y < 0)$, граница $y = 0$, вектор $\vec{w}$, расстояния $\frac{y(x)}{||w||}$ и $-\frac{w_0}{||w||}$.

Разделение на несколько классов:

- Можно рассмотреть поверхности вида «один против всех».
- Можно рассмотреть поверхности вида «каждый против каждого».

- Можно рассмотреть единый дискриминант из k линейных функций вида:
  - $y_k(x) = w_k^T x + w_k 0$.

Классифицируем в Y_k если соответствующий y_k – максимален.

---

18. Линейный дискриминантный анализ. Особенности дискриминантного анализа

(лекция 3, слайды 9–17, 19, 22; лекция 2, слайд 11)

Дискриминантный анализ – это общий термин, относящийся к нескольким тесно связанным статистическим процедурам решения задач различения (дискриминации) объектов наблюдения по набору признаков.

- Линейный ДА пытается выразить какую-либо зависимую переменную через линейную комбинацию других признаков или измерений.
- Как в дисперсионном и регрессионном анализе зависимая переменная — численная величина, является величиной номинальной (меткой класса).

Основной целью дискриминации является поиск линейной комбинации признаков (называемых дискриминантными признаками), которые позволили бы наилучшим образом разделить рассматриваемые группы.

Задачи дискриминантного анализа: Определение дискриминирующих признаков (т.е. признаков, которые позволяют отнести наблюдение к той или иной группе); Построение дискриминирующей функции; Прогнозирование будущих событий, связанных с попаданием объекта в ту или иную группу на основе значений его признака (например, предсказание выживаемости пациента после операции). Методы интерпретации межгрупповых различий (дискриминации) позволяют ответить на следующие вопросы: Возможно ли, используя данный набор переменных, отличить одну группу от другой? Насколько хорошо эти переменные позволяют провести дискриминацию? Какие из них наиболее информативны, а какие могут быть удалены из пространства признаков в связи с избыточностью?

Линейный дискриминант Фишера в первоначальном значении - метод, определяющий расстояние между распределениями двух разных классов объектов, является частным случаем гауссового байесовского классификатора. Он используется в задачах машинного обучения при статистическом (байесовском) подходе к решению задач классификации. Предположим, что обучающая выборка удовлетворяет помимо базовых гипотез байесовского классификатора также следующим гипотезам: Классы распределены по нормальному закону. Матрицы ковариаций классов равны. Тогда статистический подход приводит к линейному дискриминанту, и именно этот алгоритм классификации в настоящее время часто понимается под термином линейный дискриминант Фишера. При равенстве всех ковариационных матриц разных классов, достаточно оценить векторы математических ожиданий и общую ковариационную матрицу уже по всем объектам обучающей выборки. То есть, математические ожидания разные для каждого класса, а ковариационная матрица общая.

Подход, который предложил Фишер, заключается в следующем: В линейном случае следует спроецировать точки в размерность 1 (на нормаль разделяющей гиперплоскости) так, чтобы в этой размерности 1 они «хорошо» разделялись. То есть классификация – это метод радикального

сокращения размерности. Рассмотрим классификацию с этих позиций и попробуем добиться оптимальности в каком-то смысле.

Рассмотрим два класса $C1$ и $C2$ с $N1$ и $N2$ точками.

Идея 1 – найдём серединный перпендикуляр между центрами кластеров, так как мерой разделения спроецированных точек служит разность средних значений выборки:

$m_1 = (\frac{1}{N_1}) \sum_{C_1} x, m_2 = (\frac{1}{N_2}) \sum_{C_2} x.$

Будем максимизировать эту разность: $w^T(m2 - m1) \to max$, $||w|| = 1$.

Вместо получения дисперсий выборок определим разброс для спроецированных выборок, который будет являться оценкой выборочных дисперсий для проекции.

Для $y_n = w^T x_n$ выборочные дисперсии: $s_1 = \sum_{C_1}(y_n - m_1)^2$, $s_2 = \sum_{C_2}(y_n - m_2)^2$.

Чем отличается левый случай от правого? Слева больше дисперсия каждого кластера.

Идея 2: минимизировать перекрытие классов, оптимизируя и проекцию расстояния, и дисперсию.

Критерий Фишера:

$J(w) = \frac{(m2-m1)^2}{(s_1^2+s_2^2)} = \frac{w^T S_B w}{w^T S_W w}$,

$S_B = (m2 - m1)(m2 - m1)^T$ – ковариация между классами (between-class),

$S_W = \sum_{C_1}(x_n - m_1)(x_n - m_1)^T + \sum_{C_2}(x_n - m_2)(x_n - m_2)^T$ – ковариация внутри классов (within-class).

Ищется максимум критерия Фишера.

Критерий Фишера максимален, когда:

$(w^T \cdot S_B \cdot w) \cdot S_W w = (w^T \cdot S_W \cdot w) \cdot S_B \cdot w.$

Так как $S_B \cdot w$ будет в направлении $m_2 - m_1$, а длина w не имеет значения, получим:

$w \propto S_W^{-1}(m_2 - m_1).$

Для случая нескольких классов обобщим критерий Фишера:

$J(w) = ||S_W^{-1} S_B||$;

$S_W = \sum_{k=1..K} \sum_{C_k}(x_n - m_1)(x_n - m_1)^T$ – внутренняя дисперсия;

$S_B = S_T - S_W$ – внешняя (межклассовая) дисперсия;

$S_T = \sum_n (x_n - m)(m_n - m)^T$ – полная дисперсия.

Особенности дискриминантного анализа. Для выбранных переменных рассчитывается новая переменная Z (дискриминантная функция) – линейная комбинация исходных переменных, которая наилучшим образом разделит группы. Если группы две: получается одно уравнение. Когда групп много, получают несколько дискриминантных функций, «перпендикулярных» друг другу. Чем больше

коэффициент при переменной, тем лучше она разделяет группы, но не говорит, какие именно: $Y = w_0 + w_1x_1 + w_2x_2 + w_3x_3 + ...$

Требования к обучающим выборкам:

1. Внутри классов должно быть многомерное нормальное распределение (оценка – на основе построения гистограмм частот);
2. Гомогенность внутриклассовых дисперсий (не очень критичное требование к дисперсиям, когда для разных классов дисперсии примерно равны);
3. Не должно быть корреляции средних значений и дисперсий в классах;
4. Не должно быть чрезмерно коррелирующих друг с другом переменных.

Дискриминантная функция рассчитывается только для тех измерений, для которых известно, к какому классу они принадлежат (т.е., только для тех образов, для которых класс известен).

Линейный дискриминантный анализ (лекция 2, слайд 11).

Этот метод работает путём уменьшения размерности набора данных, проецируя все точки данных на линию. Потом он комбинирует эти точки в классы, базируясь на их расстоянии от центральной точки. Этот метод, как можно уже догадаться, относится к линейным алгоритмам классификации, т.е. он хорошо подходит для данных с линейной зависимостью.

---

19. Задача линейной регрессии. Метод наименьших квадратов (МНК)

(лекция 3, слайды 23–28)

19. Задача линейной регрессии. Метод наименьших квадратов (МНК)

(лекция 3, слайды 23–28)

Нужно найти функцию, которая отображает зависимость одних переменных или данных от других. Зависимые данные называются зависимыми переменными, выходами или ответами. Независимые данные называются независимыми переменными, входами или предсказателями. Обычно в регрессии присутствует одна непрерывная и неограниченная зависимая переменная. Входные переменные могут быть неограниченными, дискретными или категорическими данными.

Возможных функций отображения может быть много, но можно упростить задачу и искать решение только в самом простом семействе функций — линейных функций вида $y = w_1x_1 + w_2x_2 + \cdots + w_Dx_D + w_0$, где y — зависимая переменная (таргет), $(x_1, x_2, \ldots, x_D)$ — вектор, соответствующий независимым входным переменным (вектор признаков), а $w_1, w_2, \ldots, w_D, w_0$ — параметры модели. Вектор $w = (w_1, w_2, \ldots, w_D)$ часто называют вектором весов, так как на ответ модели можно смотреть как на взвешенную сумму признаков объекта, а число w_0 является свободным коэффициентом, или сдвигом. Более компактно линейную модель можно записать в виде: $y = \langle x, w \rangle + w_0$.

Если $D = 1$, то у объектов есть ровно один численный признак, по которому они отличаются. Теперь линейная модель будет выглядеть совсем просто: $y = w_1x_1 + w_0$. Для бинарной классификации объектов следует искать так называемое разделяющее правило: там, где значение функции положительно, определяется один класс объектов, где отрицательно — другой.

Модели алгоритмов для решения задач регрессии и классификации (слайд 25, рисунок): Регрессия $y = ax + b$, x — (единственный) признак, y — таргет. Классификация: $ax_1 + bx_2 + c < 0$ — Класс 0, $ax_1 + bx_2 + c > 0$ — Класс 1, $ax_1 + bx_2 + c = 0$ — разделяющая прямая, x_1, x_2 — признаки. Слайд 26: выбросы, которые исказили предсказанную зависимость (построенная зависимость и зависимость без выбросов).

Требуется, чтобы на датасете (то есть на парах (x_i, y_i) из обучающей выборки) функция f_w как можно лучше приближала искомую зависимость. Для того чтобы чётко сформулировать задачу, следует на математическом языке выразить желание «приблизить $f_w(x)$ к y», то есть необходимо научиться измерять качество модели и минимизировать её ошибку, изменяя обучаемые параметры. В данном примере обучаемые параметры — это веса w. Функция, оценивающая то, как часто модель ошибается, традиционно называется функцией ошибки, функционалом ошибки или loss function. Для решения задачи требуется минимизировать функционал ошибки. Для линейной регрессии для этого используется метод наименьших квадратов (МНК).

Через две точки на плоскости можно провести только одну прямую. Что делать, если точек на плоскости — три и более? **Метод наименьших квадратов (МНК)** состоит в том, чтобы найти такие коэффициенты регрессии, при которых достигается минимум следующего функционала ошибки на заданной обучающей выборке:

$$y'_i = y'_k(x_i) = w_k^\top x_i + w_k^0;$$

$$\sum_i (y_i - y'_i)^2 = \sum_i \left(y_i - \left(w_k^\top x_i + w_k^0\right)\right)^2 \to \min_k.$$

---

20. Логистическая регрессия. Сравнение линейной и логистической регрессии

(лекция 3, слайды 29–34; лекция 2, слайд 11)

Логистическая регрессия — это статистический метод и алгоритм машинного обучения, используемый для прогнозирования вероятности возникновения бинарного события (ответ 0 или 1, «да» или «нет») на основе одного или нескольких признаков. Несмотря на название, это метод классификации, который моделирует данные с помощью S-образной сигмоидной кривой, возвращая значения от 0 до 1.

Логистическая регрессия использует сигмоидную функцию, чтобы преобразовать линейную комбинацию признаков $y = w_1x_1 + w_2x_2 + \cdots + w_Dx_D + w_0$ в вероятность $f(y) = \frac{1}{1+e^{-y}}$, что позволяет оценивать апостериорные вероятности принадлежности классам.

Функция в правой части называется сигмоидой и обозначается σ. Таким образом, $p = \sigma(\langle w, x_i \rangle)$. Логистическая регрессия вычисляет вероятность того, что данное исходное значение принадлежит к определенному классу. Она используется для задач классификации: оценивает апостериорные вероятности принадлежности данного объекта к тому или иному классу.

Для оценки модели логистическая регрессия применяет метод **максимального правдоподобия**. Он основан на предположении о том, что вся информация о статистической выборке содержится в функции правдоподобия. Цель метода – оценить параметры распределения вероятностей. Способ – максимизировать функцию правдоподобия. Эта функция как раз определяет вероятность значений параметров регрессионной модели для заданного значения независимой переменной $x = X$: $P(\theta) =$

$P(x = X \mid \theta)$, где θ — значение параметра модели, $P(\theta)$ — вероятность появления значения θ, X — значение независимой переменной x, для которого определяется условная вероятность θ. Задача заключается в поиске таких значений параметров $\Theta = (\theta_1, \theta_2, \ldots, \theta_n)$, которые максимизируют функцию правдоподобия $L(x \mid \Theta)$. Для этого определяются оценки максимального правдоподобия, для которых значения параметров являются наиболее «правдоподобными» по отношению к наблюдаемым данным.

Слайд 32: $f(y) = \frac{1}{1+e^{-y}}$ – логистическая функция; $y = \sum_n w_n x_n$ – линейная регрессия.

Это линейный классификатор, оценивающий апостериорные вероятности классов $P(y \mid x)$, необходимые в задачах оценивания рисков. Регуляризация улучшает обобщающую способность логистической регрессии: L_2 – регуляризация сокращает веса линейно зависимых признаков; L_1 – регуляризация для отбора признаков. Для оценки коэффициентов регрессии обычно применяется метод оценки максимального правдоподобия.

Логистическая регрессия (лекция 2, слайд 11). Логистическая регрессия выводит прогнозы о точках в бинарном масштабе — нулевом или единичном. Если значение чего-либо равно либо больше 0,5, то объект классифицируется в большую сторону (к единице). Если значение меньше 0,5 — в меньшую (к нулю). … Логистическая регрессия является линейным классификатором и поэтому используется, когда в данных прослеживается какая-то линейная зависимость.

Линейная и логистическая регрессия (слайд 34, таблица):

Критерий сравнения	**Линейная регрессия**	**Логистическая регрессия**
Ввод – вывод	Ввод – независимая переменная (или несколько), вывод – прогноз зависимой переменной (задача регрессии)	Ввод – независимая переменная (или несколько), вывод – вероятность принадлежности к группе
Линия наилучшего соответствия	Прямая	Кривая
Способ минимизации ошибки	Метод наименьших квадратов	Метод максимального правдоподобия
Результат на выходе	Вещественное число (прогноз изменений)	Число в интервале от 0 до 1. Можно осуществить бинарную классификацию: если число ниже порогового значения — то объект относится к 0 («нет»), а если выше — то к 1 («да»)
Цель	Прогнозирование линейных трендов	Классификация (при добавлении соответствующего правила), но классификатором при этом не является

На рисунке слайда 30: Linear Regression — Straight line, Predicted Y can exceed 0 and 1 range; Logistic Regression — S-Curve, Predicted Y Lies within 0 and 1 range.

---

21. Метод опорных векторов (Support Vector Machines). Линейная и нелинейная разделимость классов

(лекция 3, слайды 35, 37, 41, 44–47)

Метод опорных векторов (SVM): оптимальная гиперплоскость.

Линейный дискриминант Фишера и МНК ищут разделяющую гиперплоскость, но не оптимально. Метод опорных векторов (SVM support vector machine) находит оптимальное решение. Максимизирует расстояние между гиперплоскостью и трудными точками, близкими к границе раздела. Интуитивно: если нет точек около границы раздела, то нет и сложных (неопределённых) примеров. Методы SVM принадлежит семейству линейных классификаторов и может также рассматриваться как специальный случай регуляризации по Тихонову. Особым свойством метода опорных векторов является непрерывное уменьшение эмпирической ошибки классификации и увеличение зазора, поэтому метод также известен как метод классификатора с максимальным зазором.

Основной задачей алгоритма является найти наиболее правильную линию, или гиперплоскость разделяющую данные на два класса. SVM это алгоритм, который получает на входе данные, и возвращает такую разделяющую линию. Алгоритм SVM устроен таким образом, что он ищет точки на графике, которые расположены непосредственно к линии разделения ближе всего. Эти точки называются опорными векторами. Затем, алгоритм вычисляет расстояние между опорными векторами и разделяющей плоскостью. Это расстояние которое называется зазором. Основная цель алгоритма — максимизировать расстояние зазора. Лучшей гиперплоскостью считается такая гиперплоскость, для которой этот зазор является максимально большим.

В лекции приведён пример с линейной разделимостью классов. В этом случае решение находится довольно просто. На слайде 39 можно интуитивно понять что желтая линия разделяет и соответственно классифицирует два класса лучше зеленой. Дальше представлен более сложный случай. Здесь классы линейно не разделимы.

Случай линейной разделимости (слайд 45).

Задача формулируется как поиск гиперплоскости, максимально отдалённой от выпуклой оболочки классов. Такую гиперплоскость всегда можно записать в виде линейной комбинации «опорных векторов» — прецедентов, принадлежащих выпуклой оболочке. Задачу поиска такой гиперплоскости можно записать как задачу оптимизации:

$$w = \arg\max_{w} \frac{1}{\|w\|^2} = \arg\min_{w} \|w\|^2, \qquad y_i(\langle w, x_i\rangle - b) \geq 1.$$

Решение:

$$w = \sum_{i=1}^{n} \lambda_i y_i x_i, \qquad b = \langle w, x_i\rangle - y_i.$$

$\lambda_i > 0$ — двойственные переменные. Глобальный минимум находится методом квадратичного программирования. Чисто геометрическая задача: $m = \frac{2}{||w||}$.

Нелинейная разделимость классов.

Но, этот датасет можно разделить линейно, добавив дополнительное измерение, которое мы назовем осью Z. Представим, что координаты на оси Z регулируются следующим ограничением: Z=x+y. Таким образом, ордината Z представлена из квадрата расстояния точки до начала оси. … Теперь данные можно разделить линейно. Допустим пурпурная линия разделяющая данные z=k, где k константа. Если z=x+y, то следовательно и k=x+y — формула окружности. Таким образом, мы можем спроэцировать наш линейный разделитель, обратно к исходному количеству измерений выборки, используя эту трансформацию. В результате, мы можем классифицировать нелинейный набор данных добавив к нему дополнительное измерение, а затем, привести обратно к исходному виду используя математическую трансформацию. Однако, не со всеми наборами данных можно с такой же легкостью произвести такую трансформацию. К счастью, имплементация этого алгоритма в библиотеке sklearn решает эту задачу за нас.

Особенности метода при отсутствии линейной разделимости.

Алгоритм построения оптимальной разделяющей гиперплоскости, предложенный в 1963 году Владимиром Вапником и Алексеем Червоненкисом, — алгоритм линейной классификации. Однако в 1992 году Бернхард Босер, Изабель Гийон и Вапник предложили способ создания нелинейного классификатора, в основе которого лежит переход от скалярных произведений к произвольным ядрам, так называемый kernel trick. Результирующий алгоритм крайне похож на алгоритм линейной классификации, с той лишь разницей, что каждое скалярное произведение в приведённых выше формулах заменяется нелинейной функцией ядра (скалярным произведением в пространстве с большей размерностью). Ядровые преобразования можно быстро вычислять для скалярных произведений, даже при бесконечной размерности целевого пространства. Ядра: $u \circ v = (u \cdot v)^d$; $u \circ v = \exp(-\gamma||u - v||^2), \gamma > 0$; $u \circ v = \exp\left(-\frac{||u-v||^2}{2\sigma^2}\right)$.

Теория Вапника-Червоненкиса.

Как оценить состоятельность метода? Как выбрать оптимальный, с точки зрения общего риска, алгоритм? Теория, предложенная русским математиком Владимиром Вапником (конец 60-х), для оценки способности к обучению различных моделей алгоритмов. Основные результаты теории: Оценка сложности (ёмкости) модели алгоритма; Оценка состоятельности через эмпирический риск и сложность модели.

Характеристика SVM.

Достоинства:

- Однозначность решения (глобальный минимум).
- Теоретически доказана минимальность оценки общего риска (Вапник).
- При помощи ядровых преобразований обобщается на случай сложных поверхностей.

Недостатки:

- Требует подбора множества параметров (ядро, параметры ядра, штраф за ошибки).

- Теоретические оценки верны только для случая разделимости (схема со штрафами - эвристика).
- Очень чувствителен к нормализации данных!

Замечание об опечатках в слайдах

Часть слайдов содержит опечатки, которые сохранены, чтобы не менять формулировки:

- **Вопрос 9:** определения ошибок I и II рода на слайдах 49–50 и в таблице слайдов 52–53 противоречат друг другу.
- **Вопрос 21:** «Z=x+y» должно быть $Z = x^2 + y^2$.
- **Вопрос 19:** на слайде 24 лекции 3 y назван «независимой переменной», хотя это зависимая.
- **Вопрос 20:** на слайде 31 лекции 3 сигмоида записана с минусом в знаменателе, а верно 1/(1 + e^(−y)), как на слайдах 29 и 32.